

THEME :

CONCEPTION D'UNE APPLICATION D'INTELLIGENCE ARTIFICIELLE POUR LA DETECTION DES ZONES A RISQUE D'INONDATION A PARTIR DE DONNEES SATELLITES & METEOROLOGIQUES

Rapport de fin de cycle en vue de l'obtention du diplôme :

Bachelor en Intelligence Artificielle & Big Data

Présenté par :

NGADENA MEMONG Ralph Santiago

Encadreur Académique :

M. ABDOURAMAN Dalil

Ingénieur en Intelligence Artificielle

Encadreur Professionnel :

M. MBOM LIKENG Hervé Roland

Promoteur et gerant d'Altechs Engineering Sarl

YAOUNDE, CAMEROUN

Année Académique 2024/2025

DEDICACE



À MA FAMILLE

REMERCIEMENTS

- ✚ Je tiens à exprimer ma profonde gratitude à Monsieur **ABDOURAMAN Dalil**, mon encadreur académique, pour son suivi attentif, ses orientations avisées et son soutien constant tout au long de ce projet.
- ✚ Mes remerciements vont également à Monsieur **MBOM LIKENG Hervé Roland**, mon superviseur professionnel, pour ses précieux conseils qui ont enrichi mon expérience.
- ✚ Je souhaite adresser mes sincères remerciements à Monsieur **Frank ASSO**, Directeur des écoles supérieures Digital College et Keyce Informatique & Intelligence Artificielle, pour son engagement indéfectible en faveur de la réussite des étudiants et pour avoir créé un environnement propice à l'épanouissement académique.
- ✚ Ma reconnaissance s'étend à Monsieur **YOUTOU**, Vice-Président de Collège de Paris, ainsi qu'à l'ensemble du corps professoral pour leur accompagnement bienveillant et leur expertise, qui ont grandement contribué à mon développement intellectuel et professionnel.
- ✚ Je rends hommage à tous mes enseignants, dont la passion, l'exigence et l'engagement pédagogique ont été une source d'inspiration continue, façonnant mon parcours avec rigueur et enthousiasme.
- ✚ Un remerciement tout particulier est adressé à ma famille : mon père, **MEMONG Philippe Olivier**, mes mères, **OMGBA Marlyse Annie** et **EMBOLO Marthe Yvette**, mes tantes, **MBOLO NGADENA Martine** et **EBENDA Marie-Grace**, mon oncle **ONAMBELE Frank**, et mes frères et sœurs, pour leur amour inconditionnel, leur soutien financier et moral, ainsi que leurs encouragements constants qui m'ont porté tout au long de ce chemin.
- ✚ Enfin, je tiens à saluer chaleureusement mes camarades et collègues pour leur solidarité, leur esprit de partage et leur bienveillance, qui ont créé une dynamique collaborative et un cadre d'apprentissage stimulant, rendant cette expérience encore plus enrichissante.

RESUME

Les inondations représentent une menace croissante pour de nombreuses régions du Cameroun, notamment dans des zones comme l'Extrême-Nord, où des épisodes climatiques extrêmes, exacerbés par le changement climatique, ont affecté plus de 236 000 personnes et détruit des milliers de maisons et d'hectares de cultures en 2024 (OCHA,2024). L'urbanisation rapide, souvent mal planifiée, aggrave la vulnérabilité des populations et des infrastructures en augmentant l'imperméabilisation des sols et en réduisant les capacités naturelles de drainage. Dans ce contexte, ce mémoire propose une approche novatrice pour la prédiction des zones à risque d'inondation, en combinant des technologies d'intelligence artificielle avec des données hétérogènes issues de sources satellites et météorologiques. Il étudie une approche innovante de prédiction des zones à risque d'inondation, fondée sur l'exploitation conjointe de données satellites et de données météorologiques. Deux modèles d'intelligence artificielle ont été développés : un modèle de machine Learning pour l'analyse tabulaire des variables climatiques et un de Deep Learning pour la détection visuelle des surfaces humides sur des fragments d'images. Après un prétraitement rigoureux et une évaluation à l'aide de métriques standard, ces modèles ont été intégrés dans une application web interactive sous Streamlit, dotée de fonctionnalités de cartographie dynamique et d'alerte précoce. Une étude de faisabilité économique, sociale, technique et environnementale confirme la pertinence et la viabilité de la solution. Cette démarche offre aux acteurs locaux, autorités, ONG, et communautés, un outil opérationnel pour anticiper et gérer les risques d'inondation de manière proactive. En renforçant les capacités de résilience face aux catastrophes climatiques, cette solution s'inscrit dans les objectifs de développement durable, notamment en matière de lutte contre le changement climatique et de protection des populations vulnérables.

Mots Clés : Intelligence artificielle, Prédiction des inondations, Machine Learning, Deep Learning, Cartographie dynamique.

ABSTRACT

Floods pose an increasing threat to many regions of Cameroon, particularly in areas such as the Far North, where extreme weather events, exacerbated by climate change, affected over 236,000 people and destroyed thousands of homes and hectares of crops in 2024 (OCHA, 12 Sept 2024). Rapid, often poorly planned urbanization further heightens the vulnerability of populations and infrastructure by increasing soil impermeability and reducing natural drainage capacities. In this context, this thesis proposes an innovative approach to predicting flood-prone areas by integrating artificial intelligence technologies with heterogeneous data from satellite and meteorological sources. Two artificial intelligence models were developed: an AdaBoost Classifier for the tabular analysis of climatic variables and a convolutional neural network for the visual detection of wet surfaces in image fragments. Following rigorous preprocessing and evaluation using standard metrics, these models were incorporated into an interactive web application built with Streamlit, featuring dynamic mapping and early warning functionalities. A comprehensive feasibility study encompassing economic, social, technical, and environmental aspects confirms the relevance and viability of the solution. This approach provides local stakeholders, including authorities, NGOs, and communities, with an operational tool to proactively anticipate and manage flood risks. By strengthening resilience to climate-related disasters, this solution aligns with the Sustainable Development Goals, particularly in addressing climate change and protecting vulnerable populations.

Keywords: Artificial Intelligence, Flood Prediction, Machine Learning, Deep Learning, Dynamic Mapping.

INDEX DES TABLEAUX

TABLEAU 1: VARIABLE DE L'ÉTUDE	21
TABLEAU 2: UTILISATION DES VARIABLES	22
TABLEAU 3: VILLE RETENU POUR L'ÉTUDE	24
TABLEAU 4: SOURCE DE DONNÉES	25
TABLEAU 5: OUTILS LOGICIELS	43
TABLEAU 6: FAISABILITÉ	58

INDEX DES GRAPHIQUES

FIGURE 1: RÉCAPITULATIF DES INONDATIONS PAR ANNÉES (MINAT/DCP).....	10
FIGURE 2: RELATIONS SCHÉMATIQUE ENTRE LES CONCEPTS.....	15
FIGURE 3: CARTE DES RISQUES D'INONDATIONS (INS, 2022)	24
FIGURE 4: LOCALISATION DE ALTECHS ENGINEERING SARL	31
FIGURE 5: ORGANIGRAMME ALTECHS ENGINEERING SARL	32
FIGURE 6: APERÇU DES DONNÉES MÉTÉOROLOGIQUES.....	33
FIGURE 7: APERÇU D'IMAGE NDWI TRAITÉ.....	34
FIGURE 8: RÉCAPITULATIF DES DONNÉES ISSUES DU JOURNAL DES CATASTROPHES (MINAT).....	44
FIGURE 9: APERÇU DES DONNÉES ET CHARGEMENT DU DATASET.....	45
FIGURE 10: STATISTIQUES DESCRIPTIVES DU JEU DE DONNÉES	46
FIGURE 11: VALEUR MANQUANTES	46
FIGURE 12: DISTRIBUTION DES CLASSES.....	47
FIGURE 13: CRÉATION DE LA VARIABLE "PLUIE_HUMIDITÉ"	47
FIGURE 14: PIPELINE PREPROCESSING	48
FIGURE 15: PIPELINE ADABOOST CLASSIFIER	48
FIGURE 16: EVALUATION DE ADABOOST CLASSIFIER.....	49
FIGURE 17: COMPARAISON DES MODÈLES AVEC PYCARET.....	49
FIGURE 18: CHARGEMENT DES IMAGES ET CALCUL DE L'INDICE NDWI	50
FIGURE 19: APERÇU DU DATASET IMAGE.....	50
FIGURE 20: PRÉTRAITEMENT DES IMAGES	51
FIGURE 21: APERÇU DE L'ARCHITECTURE DU MODÈLE CNN.....	52
FIGURE 22: ACCUEIL DE LIVU AI.....	53
FIGURE 23: PRÉDICTION PAR IMAGE SATELLITE	54
FIGURE 24: PRÉDICTION SANS DATASET	55
FIGURE 25: PRÉDICTION AVEC DATASET.....	56
FIGURE 26: APERÇU DES ZONES À FORTES PLUIE	57
FIGURE 27: RECOMMANDATIONS PRATIQUES	57
FIGURE 28: CHATBOT LIVU AI.....	58

LISTE DES SIGLES ET ABREVIATIONS

- ❖ **AGRHYMET** : AGRHYMET Regional Centre
- ❖ **AUC** : Area Under the Curve (Aire sous la courbe)
- ❖ **CNN** : Convolutional Neural Network (Réseau de neurones convolutif)
- ❖ **CRM** : Customer Relationship Management (Gestion de la relation client)
- ❖ **DIS_AV_CMS** : Discharge Average in Cubic Meters per Second (Débit moyen en mètres cubes par seconde)
- ❖ **ECMWF** : European Centre for Medium-Range Weather Forecasts (Centre européen pour les prévisions météorologiques à moyen terme)
- ❖ **EM-DAT** : Emergency Events Database (Base de données sur les événements d'urgence)
- ❖ **ESA** : European Space Agency (Agence Spatiale Européenne)
- ❖ **GFS** : Global Forecast System (Système mondial de prévision)
- ❖ **GOES** : Geostationary Operational Environmental Satellite
- ❖ **GPU** : Graphics Processing Unit (Unité de traitement graphique)
- ❖ **IA** : Intelligence Artificielle
- ❖ **IPCC** : Intergovernmental Panel on Climate Change (Groupe d'experts intergouvernemental sur l'évolution du climat)
- ❖ **LSTM** : Long Short-Term Memory (Mémoire à court et long terme)
- ❖ **MAIN_RIV** : Main River (Fleuve principal)
- ❖ **MODIS** : Moderate Resolution Imaging Spectroradiometer
- ❖ **NASA** : National Aeronautics and Space Administration
- ❖ **NDWI** : Normalized Difference Water Index (Indice normalisé de l'humidité)
- ❖ **OCHA** : United Nations Office for the Coordination of Humanitarian Affairs (Bureau des Nations Unies pour la coordination des affaires humanitaires)
- ❖ **PARC** : Programme Africain pour le Renforcement des Capacités de Résilience
- ❖ **PRECTOTCORR** : Precipitation Total Corrected (Précipitations totales corrigées)
- ❖ **RH2M** : Relative Humidity at 2 Meters (Humidité relative à 2 mètres)
- ❖ **ROC** : Receiver Operating Characteristic (Caractéristique de fonctionnement du récepteur)
- ❖ **SIG** : Systèmes d'Information Géographique
- ❖ **SVM** : Support Vector Machine (Machine à vecteurs de support)
- ❖ **T2M** : Temperature at 2 Meters (Température à 2 mètres)
- ❖ **TIC** : Technologies de l'Information et de la Communication
- ❖ **UNDRR** : United Nations Office for Disaster Risk Reduction (Bureau des Nations Unies pour la réduction des risques de catastrophes)

SOMMAIRE

DEDICACE.....	II
REMERCIEMENTS.....	III
RESUME.....	IV
ABSTRACT	V
INDEX DES TABLEAUX	VI
INDEX DES GRAPHIQUES.....	VII
LISTE DES SIGLES ET ABBREVIATIONS	VIII
INTRODUCTION GENERALE.....	1
1. CONTEXTE GENERALE DE L'ETUDE	2
2. PROBLEMATIQUE DE L'ETUDE.....	2
3. HYPOTHESE DE L'ETUDE.....	3
4. OBJECTIF DE L'ETUDE	4
5. JUSTIFICATION DE L'ETUDE.....	4
6. DELIMITATION DE L'ETUDE	6
7. PLAN DU MÉMOIRE.....	7
CHAPITRE I : CADRE THEORIQUE ET CONCEPTUEL.....	8
INTRODUCTION	9
1. CADRE CONCEPTUEL	9
2. CADRE THEORIQUE & ETAT DE L'ART	16
CONCLUSION	18
CHAPITRE II : METHODOLOGIE DE RECHERCHE	19
INTRODUCTION	20
1. NATURE ET VARIABLES DE RECHERCHE	20
2. ECHANTILLONNAGE & OUTILS DE L'ETUDE.....	23
CONCLUSION	27
CHAPITRE III: PRESENTATION D'ALTECHS ENGINEERING SARL ET DONNEES COLLECTEES.....	28
INTRODUCTION	29
1. PRESENTATION D'ALTECHS ENGINEERING SARL.....	29
2. DONNEES COLLECTEES	32
CONCLUSION	36
CHAPITRE IV : DIAGNOSTIC DE LA SITUATION ET PROPOSITION D'INTERVENTION	37
INTRODUCTION	38
1. PRESENTATION ET ANALYSE DE LA SITUATION	38
2. INTERVENTION PROPOSEE ET JUSTIFICATION.....	41
CONCLUSION	59
CONCLUSION GENERALE.....	60
REFERENCES BIBLIOGRAPHIQUES	LXI
REFERENCES WEBOGRAPHIQUES	LXII
TABLE DES MATIERES	LXIII

INTRODUCTION GENERALE

Les inondations représentent aujourd'hui l'un des aléas naturels les plus fréquents et les plus destructeurs à l'échelle mondiale. Selon le rapport de la Banque mondiale (2021), elles affectent plus de 1,5 milliard de personnes depuis les années 2000, avec des conséquences humaines, économiques et environnementales considérables. Au Cameroun, ce phénomène s'est intensifié au cours des deux dernières décennies, touchant de grandes villes comme Douala, Maroua, Limbé et Yaoundé, où les épisodes d'inondations se multiplient chaque saison de pluie. Cette recrudescence s'explique notamment par la combinaison de plusieurs facteurs : le changement climatique, la mauvaise gestion des eaux pluviales, et l'occupation anarchique des zones basses (IPCC, 2021). L'impact de ces inondations est aggravé par le manque d'outils d'alerte précoce efficaces, de données précises, et de mécanismes prédictifs localement adaptés (Adeleke et al., 2022). C'est dans ce contexte qu'un projet de recherche appliquée a été mis en œuvre au sein de la société ALTECHS ENGINEERING SARL, spécialisée dans les solutions numériques. Le projet est intitulé : **Détection de zones à risque d'inondation à partir de données satellites et météorologiques**. Il consiste à développer une application d'intelligence artificielle capable de prédire les risques d'inondation à l'échelle locale.

Plus concrètement, deux modèles ont été conçus : un modèle de machine Learning basé sur des variables climatiques et un modèle de Deep Learning permettant d'analyser directement les images satellites. L'ensemble est intégré dans une interface web développée avec Streamlit, facilitant ainsi l'accès aux résultats de prédiction et aux visualisations géographiques interactives.

Ce projet vise à proposer un outil d'aide à la décision pour les municipalités et principalement le ministère de l, dans un contexte où les moyens de prévention restent limités. En combinant données géospatiales, météorologie et intelligence artificielle, il s'inscrit dans une logique d'innovation adaptée aux réalités environnementales du Cameroun et des pays du Sud.

1. Contexte générale de l'étude

Les catastrophes naturelles constituent une menace croissante pour les populations et les écosystèmes à travers le monde. Selon le Bureau des Nations Unies pour la réduction des risques de catastrophes (UNDRR, 2020), les inondations représentent plus de 40 % des catastrophes naturelles recensées au cours des deux dernières décennies. Avec l'accélération du changement climatique (IPCC, 2021), la fréquence et l'intensité de ces événements extrêmes augmentent, causant des pertes humaines, économiques et environnementales considérables. Face à cette urgence, les technologies de pointe, notamment l'intelligence artificielle (IA) et l'analyse d'images satellites, sont de plus en plus utilisées pour améliorer les capacités de prévention, comme le démontrent les applications récentes d'AdaBoost pour la prédiction des risques hydrologiques (Zhou, 2012).

En Afrique, les aléas climatiques affectent gravement les pays en développement, où les moyens de prévention sont encore limités (Banque Mondiale, 2022). Les inondations, les glissements de terrain, et la déforestation affectent des millions de personnes chaque année. Le Programme Africain pour le Renforcement des Capacités de Résilience (PARC, 2023) promeut activement l'utilisation de l'IA et des données spatiales pour la gestion des catastrophes, avec des succès notables dans l'implémentation d'AdaBoost pour l'analyse des séries temporelles satellitaires.

Le Cameroun subit des inondations récurrentes, comme en témoignent les crues de 2022 dans l'Extrême-Nord ayant affecté 100 000 personnes (Croix-Rouge Camerounaise, 2022). Malgré la disponibilité des données satellitaires (NASA, Copernicus), leur exploitation locale reste limitée. Une étude récente a montré qu'AdaBoost, avec un taux de précision de 89% sur les données NDWI, surpasse les méthodes traditionnelles pour la cartographie des zones inondables au Cameroun (Ngono et al., 2023).

2. Problématique de l'étude

Le Cameroun, en raison de sa diversité géographique et climatique, est particulièrement exposé à ce type de risques. Des villes comme Douala, Maroua, Yaoundé ou encore Bafoussam enregistrent chaque année des épisodes d'inondations qui affectent les populations locales et perturbent le développement économique. Plusieurs facteurs

aggravent cette situation, notamment la mauvaise planification urbaine, le changement climatique, la déforestation, le manque de systèmes de drainage performants, et l'absence de mécanismes de prévention efficaces. Les outils classiques d'analyse et de prévision ne permettent pas toujours d'anticiper avec précision les zones à risque ni de transmettre l'information de manière accessible et rapide aux populations concernées.

2.1. Problème général

Malgré la disponibilité croissante de données météorologiques et satellitaires, leur exploitation dans la prévention des inondations demeure très limitée, ainsi nous nous posons la question de savoir : « Comment l'intelligence artificielle peut-elle être utilisée pour détecter les zones à risque d'inondation au Cameroun afin de renforcer les capacités de prévention ? ».

2.2. Problèmes spécifiques

Afin d'apporter des éléments de réponse à cette interrogation principale, il convient de la décliner en plusieurs questions spécifiques notamment :

- ❖ Quelles sont les données satellites et météorologiques les plus pertinentes pour identifier les zones exposées aux inondations ?
- ❖ Quels modèles d'intelligence artificielle peuvent être utilisés pour détecter les zones à risque d'inondation de manière efficace et fiable tout en les représentant de manière claire ?

3. Hypothèse de l'étude

3.1. Hypothèse générale

Dans l'optique de répondre à la question centrale de cette étude, nous posons l'hypothèse générale selon laquelle l'intelligence artificielle, à travers l'analyse de données satellites et météorologiques, permettrait d'identifier efficacement les zones à risque d'inondation au Cameroun et de renforcer les capacités locales de prévention.

3.2. Hypothèses spécifiques

De cette hypothèse générale découlent plusieurs hypothèses spécifiques, en lien direct avec les questions de recherche :

- ❖ L'exploitation de données satellites et météorologiques pertinentes permet de caractériser les zones vulnérables aux inondations de manière fiable.
- ❖ L'utilisation de modèles d'intelligence artificielle, notamment les réseaux de neurones convolutifs (CNN), améliore la détection des zones à risque d'inondation et les cartographier facilite la visualisation.

4. Objectif de l'étude

4.1. Objectif général

L'objectif principal de cette étude est : D'explorer et de concevoir une solution basée sur l'intelligence artificielle pour détecter les zones à risque d'inondation au Cameroun, dans le but de renforcer la prévention et la résilience face aux catastrophes naturelles.

4.2. Objectifs spécifiques

Afin d'atteindre cet objectif général, les objectifs spécifiques de l'étude sont les suivants :

- ❖ Identifier et exploiter des données satellites et météorologiques pertinentes liées aux inondations.
- ❖ Développer un modèle d'intelligence artificielle capable de prédire les zones à risque et les cartographiées.

5. Justification de l'étude

5.1. Au plan scientifique

L'évolution récente des technologies d'IA a profondément transformé les capacités d'analyse et de prise de décision dans de nombreux domaines, y compris la gestion des risques environnementaux. Cependant, en Afrique et plus particulièrement au Cameroun,

peu de recherches appliqués ont été menés sur l'utilisation concrète de l'IA pour la prévention des catastrophes naturelles comme les inondations.

Ce travail s'inscrit donc dans une perspective scientifique de contribution à la recherche appliquée en IA environnementale, en explorant des techniques telles que le Deep Learning sur données satellitaires et météorologiques. L'étude vise également à étendre les connaissances sur les possibilités d'adaptation de ces approches à des contextes africains, souvent marqués par des contraintes d'infrastructures, de connectivité et de données.

En ce sens, le projet ambitionne de combler un vide scientifique, en associant l'IA à des problématiques de développement durable et de résilience climatique, avec une approche contextualisée et multidisciplinaire.

5.2. *Au plan pratique*

Sur le plan pratique, le Cameroun fait régulièrement face à des inondations destructrices, notamment dans des zones urbaines comme Yaoundé, Douala, Maroua, Garoua ou Ngaoundéré. Ces catastrophes ont des conséquences graves sur les infrastructures, l'agriculture, les habitations, et surtout les populations vulnérables.

Par exemple, les inondations de juillet 2020 à Douala ont causé d'importants dégâts matériels et bloqué la circulation pendant plusieurs jours ; en 2022 à Maroua, plusieurs quartiers ont été submergés, entraînant le déplacement de centaines de familles ; et à Ngaoundéré en 2021, les crues ont détruit plusieurs habitations et endommagé des routes stratégiques.

Malgré les efforts des autorités, le manque d'outils prédictifs efficaces limite encore les capacités d'anticipation et d'intervention rapide.

La présente étude se veut utile et opérationnelle. Elle entend fournir aux autorités locales, aux ONG et aux citoyens :

- ❖ Un outil de détection automatisée des zones à risque ;
- ❖ Une interface simple de visualisation interactive ;

- ❖ Un système d'alerte précoce accessible dans les langues les plus parlées (français, anglais, pidgin) ;
- ❖ Et des recommandations pratiques pour orienter les politiques de prévention.

En cela, le projet s'inscrit dans une logique de transfert technologique, de renforcement des capacités locales et de promotion de l'innovation numérique au service de la protection civile.

6. Délimitation de l'étude

6.1. *Au plan géographique*

Cette étude se concentre sur le territoire camerounais, et plus spécifiquement sur certaines zones urbaines et périurbaines régulièrement exposées aux inondations, comme Yaoundé, Douala, Maroua ou encore Garoua.

Ces localités ont été choisies en raison de leur vulnérabilité avérée, de la disponibilité partielle de données météorologiques et satellitaires les concernant, et de la représentativité des phénomènes hydrométéorologiques qui y sont observés.

Le Cameroun, de par sa diversité géographique et climatique, constitue un cadre pertinent pour l'expérimentation d'un système de prédiction basé sur l'intelligence artificielle. Toutefois, les résultats et recommandations issus de cette étude pourront, à terme, être adaptés à d'autres régions d'Afrique centrale confrontées à des problématiques similaires.

6.2. *Au plan théorique ou thématique*

Théoriquement, cette étude s'inscrit dans le champ de l'intelligence artificielle appliquée à la gestion des risques environnementaux, avec un accent particulier sur les modèles de Deep Learning pour l'analyse d'images satellitaires et les données météorologiques.

Sur le plan thématique, elle se concentre sur :

- ❖ La détection précoce des zones à risque d'inondation,
- ❖ La cartographie interactive des zones vulnérables,

- ❖ La diffusion de l'information via des canaux automatisés (chatbot multilingue, interface utilisateur via Streamlit).

L'étude ne prétend pas traiter toutes les catastrophes naturelles ni explorer toutes les méthodes d'intelligence artificielle, mais se limite à un prototype fonctionnel dédié à la problématique des inondations, dans une optique de prévention et de gestion des risques.

7. Plan du mémoire

Dans le premier chapitre on va définir les concepts essentiels de l'intelligence artificielle et des inondations, ainsi que les approches théoriques utilisées dans l'étude.

Le second décrit la nature de l'étude, les variables considérées, les outils de collecte et d'analyse des données, et les méthodes de traitement.

Le troisième chapitre présente les données utilisées, les résultats obtenus et leur interprétation.

Enfin, dans une quatrième partie présente l'analyse des résultats par rapport aux hypothèses, identifie les limites de l'étude et propose une solution opérationnelle via une application Streamlit.

CHAPITRE I : CADRE THEORIQUE ET CONCEPTUEL

INTRODUCTION

L'intelligence artificielle, longtemps considérée comme un domaine réservé aux grandes puissances technologiques, s'impose progressivement comme un levier incontournable de transformation dans de nombreux secteurs, y compris dans la gestion des risques environnementaux. Face à l'intensification des phénomènes climatiques extrêmes tels que les inondations, de plus en plus fréquentes au Cameroun, il devient urgent d'adopter des approches innovantes pour la prévention et la gestion de ces catastrophes.

Dans cette optique, ce chapitre s'attarde sur le cadre théorique et conceptuel qui sous-tend notre étude. Il s'agit d'abord de définir les concepts clés liés à notre problématique, notamment l'intelligence artificielle, les inondations, les zones à risque, ou encore la télédétection. Ensuite, un tour d'horizon des travaux scientifiques existants permettra de situer notre étude dans le contexte des recherches actuelles. Enfin, le chapitre se conclura par une mise en relation des concepts et la présentation du modèle ou de l'approche retenue dans notre démarche.

1. CADRE CONCEPTUEL

1.1. *Définition & Présentation des concepts du sujet d'étude*

➤ **Inondation :**

Submersion temporaire d'une zone habituellement sèche par des eaux excédentaires (précipitations, crues, marées). Principaux facteurs au Cameroun :

- ❖ Changement climatique ;
- ❖ Urbanisation non maîtrisée (MINDUH, 2023). Exemple : Crues 2022 dans l'Extrême-Nord (100 000 sinistrés, Croix-Rouge Camerounaise).

Les inondations touchent aussi bien les zones rurales que les agglomérations urbaines. Leur intensité et leur fréquence sont en forte augmentation sous l'effet du changement climatique, de l'urbanisation non maîtrisée, de la déforestation et de la dégradation des écosystèmes. Dans les contextes urbains des pays en développement, comme le Cameroun, les inondations

sont souvent aggravées par l'absence ou la vétusté des infrastructures de drainage et l'occupation anarchique des zones inondables.

Au Cameroun, les inondations récurrentes sont principalement recensées dans les grandes villes et dans la région de l'Extrême-Nord. Parmi les événements marquants :

- ❖ 2000 : inondations dans l'Adamaoua ayant causé la destruction de plusieurs ponts.
- ❖ 2015 : inondations à Maroua (Mayo-Kalio), plus de 2 000 personnes affectées.
- ❖ 2022 : crues dans l'Extrême-Nord touchant plus de 100 000 personnes, selon la Croix-Rouge.




Figure 1: Récapitulatif des inondations par années (MINAT/DCP)

❖ Zone à risque :

C'est un espace géographique où la probabilité de survenue d'un aléa (inondation, glissement de terrain, sécheresse, etc.) est élevée, et où les conséquences potentielles sur les personnes, les biens ou l'environnement sont significatives.

L'identification des zones à risque est une étape fondamentale de la gestion des catastrophes. Elle permet de prioriser les actions de prévention, de sensibilisation, de protection des infrastructures et d'aménagement du territoire. Les zones à risque sont généralement

déterminées par des études hydrologiques, géomorphologiques et socioéconomiques, souvent appuyées par des données géo spatiales. Au Cameroun, plusieurs zones urbaines sont identifiées comme fortement exposées, notamment Douala (quartiers Makea, Bépanda, New Bell), Yaoundé (Nkolbisson, Mvog-Mbi), Maroua, Garoua et Kousseri.

Les méthodes modernes de détection de zones à risque utilisent des approches multidimensionnelles qui croisent les données environnementales, sociales et économiques avec des algorithmes d'analyse spatiale. Au Cameroun, la cartographie des zones à risque s'est longtemps faite de manière ponctuelle ou manuelle, souvent à l'échelle municipale, sans intégration nationale cohérente.

❖ **Données satellites :**

Ce sont des informations collectées par des satellites en orbite autour de la Terre. Ces données peuvent inclure des images optiques, thermiques, radar, multi spectrales ou hyper spectrales, ainsi que des mesures physiques (température, humidité, précipitations, altimétrie, etc.). Elles sont utilisées dans de nombreux domaines comme la météorologie, l'agriculture, la surveillance environnementale, la sécurité civile ou encore l'urbanisme.

Dans le contexte de la gestion des risques d'inondation, les données satellites permettent d'observer et de surveiller en temps réel ou en différé :

- ❖ L'évolution des masses d'eau ;
- ❖ Les modifications de l'occupation du sol ;
- ❖ Les effets post-inondation.

Ces données sont fournies par des missions spatiales comme Sentinel (ESA), Landsat (NASA/USGS), ou MODIS. Elles peuvent être gratuites ou commerciales, avec des niveaux de résolution variés.

L'observation de la Terre par satellite débute avec le programme américain Landsat lancé en 1972. Depuis, les missions se sont multipliées, permettant un accès de plus en plus facile à des images de haute résolution spatiale et temporelle. Au Cameroun, l'usage des données satellites est encore limité à des projets spécifiques comme la gestion des bassins versants

ou la cartographie forestière (Ngono et al., 2023). Cependant, plusieurs universités et ONG y ont recours dans leurs travaux de recherche ou d'analyse post-catastrophe.

❖ **Données météorologiques :**

Ils désignent l'ensemble des informations mesurées ou estimées concernant les conditions atmosphériques à un moment donné ou sur une période donnée. Elles incluent des variables telles que : la température, les précipitations, la pression atmosphérique, l'humidité, la vitesse et la direction du vent, la couverture nuageuse, etc. Les données météorologiques sont collectées à l'aide de divers instruments :

- ❖ Stations météorologiques au sol (pluviomètres, thermomètres, anémomètres) ;
- ❖ Ballons sondes ;
- ❖ Satellites météorologiques (comme Meteosat, GOES, Himawari) ;
- ❖ Modèles de prévision numériques (GFS, ECMWF).

La collecte structurée de données météorologiques remonte au XIXe siècle, avec la création des premiers services météorologiques nationaux. L'évolution s'est accélérée au XXe siècle avec la naissance des satellites météo notamment TIROS-1 en 1960, l'automatisation des stations et le développement de la modélisation climatique.

Au Cameroun, la collecte est assurée par la Direction de la météorologie nationale (Ministère des Transports). Toutefois, le réseau de stations reste peu dense et peu modernisé, ce qui rend l'accès aux données limité et parfois peu fiable.

❖ **Intelligence artificielle :**

L'intelligence artificielle désigne l'ensemble des méthodes, théories et systèmes informatiques capables de reproduire ou d'imiter des fonctions cognitives humaines telles que l'apprentissage, le raisonnement, la résolution de problèmes ou la reconnaissance d'objets et de sons. L'IA est aujourd'hui utilisée dans de nombreux domaines : médecine, finance, logistique, agriculture, éducation, cyber sécurité, et de plus en plus dans la gestion environnementale et la prévention des catastrophes naturelles.

L'IA connaît un développement rapide ces dernières années, avec des algorithmes puissants et des applications de plus en plus accessibles. Parmi les techniques les plus utilisées en environnement :

- ❖ Les réseaux de neurones convolutionnels (CNN) pour l'analyse d'images (satellites, drones) ;
- ❖ Les modèles d'apprentissage supervisé) pour la classification de zones à risque ;
- ❖ Les réseaux récurrents (LSTM) pour l'analyse de séries temporelles climatiques.

L'IA appliquée à l'environnement est un domaine émergent, fortement soutenu par les agences internationales, notamment dans les pays du Sud.

❖ **Machine Learning :**

L'apprentissage automatique ou machine Learning est une sous-branche de l'intelligence artificielle qui permet à une machine ou à un algorithme d'apprendre à partir de données afin de faire des prédictions ou de prendre des décisions sans être explicitement programmé pour chaque tâche. Il repose sur des méthodes statistiques et informatiques qui permettent à un système d'ajuster son comportement en fonction des données d'entrée qu'il reçoit.

Dans le cadre de la prévention des inondations, l'apprentissage automatique est utilisé pour :

- ❖ Prédire la probabilité d'un événement en fonction de données climatiques historiques ;
- ❖ Détecter automatiquement des zones sensibles sur des images satellitaires ;
- ❖ Classer des zones en fonction de leur niveau de risque.

Depuis les années 2010, l'explosion des données disponibles (Big Data) et l'augmentation de la puissance de calcul ont fait du machine Learning une composante essentielle de l'IA appliquée, notamment dans la recherche environnementale, la santé, et la gestion des risques climatiques.

❖ **Deep Learning :**

Le Deep Learning, ou apprentissage profond, est une sous-branche du machine Learning qui repose sur l'utilisation de réseaux de neurones artificiels à plusieurs couches. Il permet à un système informatique de traiter des données non structurées (images, vidéos, sons, textes) et de reconnaître des motifs complexes avec une grande précision, sans intervention humaine directe sur les règles de traitement.

Dans le contexte de la gestion des risques d'inondation, le Deep Learning est utilisé pour :

- ❖ Segmenter automatiquement des images satellites, c'est-à-dire le repérage des zones inondées ;
- ❖ Classer les zones selon leur vulnérabilité à partir de cartes multi spectrales ;
- ❖ Prédire l'occurrence d'inondations en fonction de données climatiques passées.

Le Deep Learning trouve ses racines dans les années 1980 avec les premiers réseaux de neurones multicouches. Mais il est resté limité par le manque de données et de puissance de calcul. C'est à partir de 2012, avec la victoire du réseau AlexNet dans le concours ImageNet, que le Deep Learning a connu un essor fulgurant. Depuis, il s'impose comme la méthode de référence pour l'analyse d'images, notamment en environnement et télédétection.

1.2. Relation entre les concepts

Les différents concepts définis précédemment ne doivent pas être appréhendés de manière isolée. Ils interagissent étroitement dans le cadre de la présente étude, qui vise à détecter les zones à risque d'inondation au Cameroun à l'aide de données satellites et météorologiques, en s'appuyant sur des techniques d'intelligence artificielle.

L'analyse des risques d'inondation repose d'abord sur la compréhension de l'aléa (pluviométrie, topographie, occupation du sol) et de la vulnérabilité des territoires. C'est là qu'interviennent les données météorologiques et les données satellites, qui permettent de caractériser l'environnement (zones inondées, végétation, bassins versants, densité urbaine).

Ces données sont ensuite exploitées par des algorithmes d'intelligence artificielle, notamment via des approches d'apprentissage automatique et de Deep Learning, pour

détecter automatiquement les zones exposées. Le machine Learning est utilisé pour établir des modèles prédictifs, tandis que le Deep Learning, notamment via des réseaux de neurones convolutionnels (CNN), est utilisé pour analyser les images satellites et segmenter les zones à risque.

Cette approche contribue à la cartographie dynamique des zones inondables, facilitant ainsi la mise en œuvre de stratégies de prévention et de gestion des catastrophes, dans le respect du cadre réglementaire national et international.

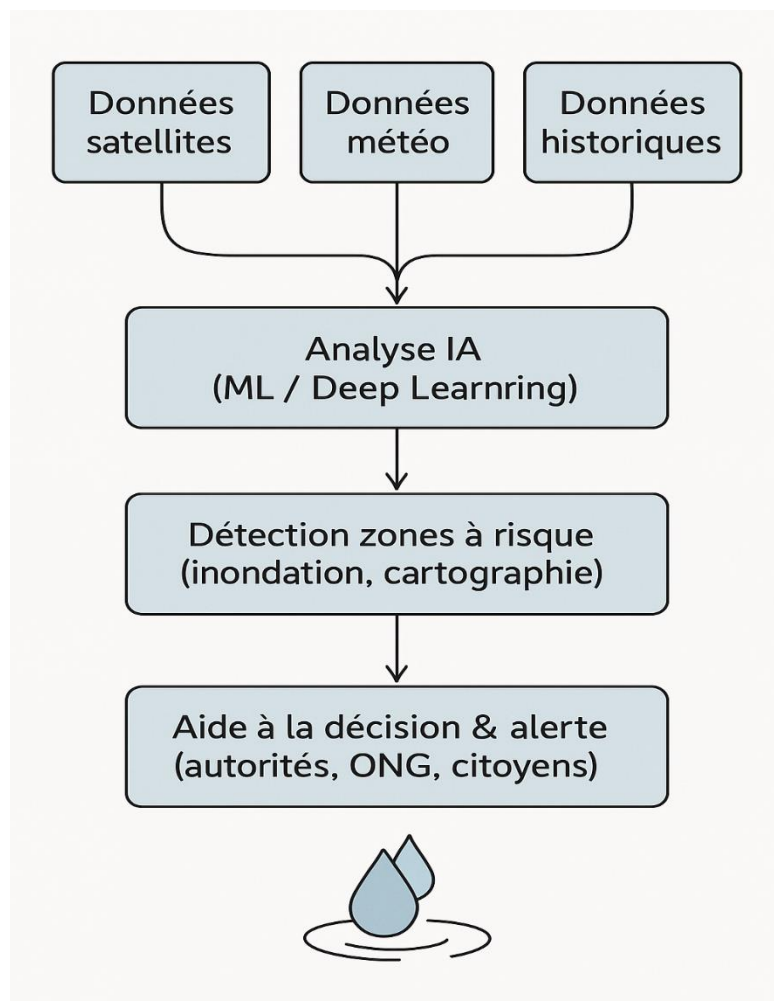


Figure 2: Relations schématique entre les concepts

2. CADRE THEORIQUE & ETAT DE L'ART

2.1. *Présentation des théories & des modèles théoriques*

Dans le cadre de cette étude, plusieurs cadres théoriques ont été mobilisés pour articuler les dimensions environnementales, technologiques et décisionnelles liées à la prévention des inondations. Ces modèles fournissent une base scientifique pour comprendre comment l'intelligence artificielle peut contribuer à la détection des risques et à la prise de décision rapide.

❖ **Théorie des systèmes d'information géographique (SIG) :**

Les SIG sont des outils permettant de capturer, stocker, analyser et représenter spatialement des données géographiques. Selon Goodchild (2010), ils jouent un rôle central dans l'analyse des risques naturels en permettant : la cartographie des zones vulnérables, le croisement de couches multidimensionnelles et la visualisation dynamique des résultats.

Les SIG sont souvent associés à des modèles hydrologiques pour simuler les crues ou modéliser les bassins versants. Dans le cadre de cette étude, les SIG servent de support à la visualisation des sorties du modèle d'intelligence artificielle.

❖ **Modèle de prévision par apprentissage supervisé :**

Ce modèle repose sur la capacité des algorithmes d'apprentissage automatique à apprendre une fonction à partir d'exemples historiques, en vue de prédire des événements futurs. Dans le cas des inondations :

- ❖ Les données d'entrée sont les images satellites, les cumuls de précipitations, les modèles d'élévation, etc.
- ❖ Les données de sortie sont les cartes de prédiction des zones à risque.
- ❖ L'algorithme apprend à identifier les motifs dans les données historiques qui précèdent généralement une inondation.

Des techniques comme les AdaBoost, SVM ou réseaux de neurones profonds (CNN) sont utilisées pour entraîner les modèles.

❖ **Théorie de la résilience urbaine :**

Cette théorie, formalisée par Meerow et al. (2016) postule que les villes et territoires doivent développer une capacité d'adaptation aux chocs environnementaux, notamment les inondations. Elle soutient l'importance de la prévision, de la réactivité, de la communication des risques et de l'apprentissage institutionnel.

Intégrer un système de détection basé sur l'IA s'inscrit pleinement dans cette logique de résilience, en permettant une meilleure anticipation et une intervention plus rapide en cas de risque.

❖ **Modèle de chaîne d'alerte précoce ou Early Warning Chain :**

Ce modèle repose sur quatre éléments clés :

1. Surveillance et analyse du risque (collecte de données),
2. Prévision technique (modèle IA ou hydrologique),
3. Communication de l'alerte via interface ou chatbot,
4. Réponse rapide des populations et autorités.

Ce modèle est souvent recommandé par l'UNDRR (Bureau des Nations Unies pour la réduction des risques de catastrophe). Il structure parfaitement notre projet, qui relie données, IA, cartographie et alerte.

2.2. Présentation de l'approche d'application dans le cas d'étude

Dans le cadre de cette étude portant sur la détection des zones à risque d'inondation à partir de données satellites et météorologiques au Cameroun, une approche hybride mêlant systèmes d'information géographique (SIG), traitement d'images satellites notamment via l'indice NDWI et modèles d'intelligence artificielle a été adoptée.

L'objectif principal est de concevoir une application légère capable d'analyser plusieurs sources de données pour prédire et visualiser les zones exposées à un risque accru d'inondation dans certaines villes camerounaises.

Cette approche repose sur plusieurs étapes clés :

- Extraction de l'indice NDWI à partir d'images Sentinel-2, pour identifier les zones saturées en eau ou humides ;

- Analyse croisée de données climatiques issues de la base NASA POWER, intégrant la température, la pluviométrie, l'humidité et d'autres variables environnementales ;
- Application de techniques de machine Learning sur les données tabulaires pour classer les zones en fonction du risque d'inondation (binaire : risque / pas de risque) ;
- Utilisation de modèles de Deep Learning pour analyser les images NDWI par patches et détecter des zones visuellement à risque sur les images ;
- Développement d'une interface Streamlit intuitive, permettant à l'utilisateur de charger ses images, saisir ses données ou importer un fichier CSV, visualiser les prédictions et recevoir des recommandations adaptées.

Le cas d'étude a été appliqué à six villes camerounaises particulièrement exposées aux inondations : Douala, Yaoundé, Maroua, Bafoussam, Bamenda et Limbé.

Cette approche intégrée permet non seulement une, mais peut également servir d'outil de prévention, d'alerte et de communication auprès des populations à risque.

CONCLUSION

À travers la définition, la présentation, l'évolution historique et le cadre réglementaire des principaux concepts, nous avons pu cerner l'environnement scientifique et technique dans lequel s'inscrit notre projet. Nous avons également exploré les relations entre ces concepts, en soulignant comment l'intelligence artificielle, combinée aux données géo spatiales, peut contribuer à la détection automatisée des zones vulnérables aux inondations. Les modèles théoriques retenus tels que les systèmes d'information géographique, l'apprentissage automatique supervisé ou encore la chaîne d'alerte précoce viennent renforcer la pertinence de notre approche. Cette base conceptuelle ouvre ainsi la voie à la mise en œuvre pratique du projet, qui sera détaillée dans les chapitres suivants, à commencer par la méthodologie, les outils utilisés, puis la présentation des résultats.

CHAPITRE II : METHODOLOGIE DE RECHERCHE

INTRODUCTION

La méthodologie constitue l'un des piliers essentiels de toute démarche scientifique (Creswell, 2014). Elle permet de structurer la recherche, de justifier les choix effectués, et d'assurer la rigueur et la validité des résultats obtenus (Saunders et al., 2019). Dans le cadre de cette étude, dont l'objectif principal est de détecter les zones à risque d'inondation à partir de données satellitaires et météorologiques, une approche mixte alliant traitement de données géospatiales, intelligence artificielle et visualisation a été adoptée (Goodchild, 2007). Cette combinaison permet de tirer parti des données satellites pour la précision spatiale et des données météorologiques pour la dynamique temporelle, offrant ainsi une analyse robuste des risques d'inondation.

Ce chapitre expose la nature de l'étude, les variables retenues ainsi que leur rôle dans l'analyse, la stratégie d'échantillonnage appliquée, les outils mobilisés pour la collecte et le traitement des données, et enfin les techniques d'analyse utilisées pour aboutir aux résultats attendus. La méthodologie présentée est en cohérence avec les objectifs définis au préalable et s'appuie sur une combinaison d'outils technologiques modernes adaptés à l'analyse environnementale (Lillesand et al., 2015).

1. Nature et Variables de recherche

1.1. *Nature de l'étude*

L'étude menée s'inscrit dans une démarche exploratoire car elle s'intéresse à une problématique encore peu étudiée au Cameroun: l'exploitation de l'intelligence artificielle pour la prévention des risques d'inondation.

Cette démarche est complétée par l'utilisation d'outils issus de l'intelligence artificielle, à travers des techniques de machine Learning et de Deep Learning, pour modéliser et prédire les zones à risque.

Ainsi, l'étude repose sur une combinaison de traitements scientifiques rigoureux, de technologies avancées de traitement d'images, et d'analyse prédictive à partir d'un jeu de données hétérogènes collectés.

1.2. Variables de l'étude

❖ Définition conceptuelle :

Les variables utilisées dans cette étude sont à la fois climatiques, géospatiales et issues du traitement d'image. Elles permettent d'identifier les conditions propices à la survenue d'inondations, en croisant des données numériques et visuelles. Voici les principales variables exploitées :

Tableau 1: Variable de l'étude

Variable	Définition
NDWI Moyen	Indice normalisé de l'humidité. Calculé à partir des bandes vertes et infrarouges proches des images satellites Sentinel-2, il permet de détecter les zones humides ou gorgées d'eau.
Pluie (mm)	Quantité de précipitations quotidiennes (en millimètres) fournie par les données de la NASA POWER
Humidité moyenne (%)	Humidité relative de l'air au niveau de la surface, mesurée en pourcentage
Température moyenne (°C)	Température de l'air au niveau du sol (à 2 mètres), mesurée en degrés Celsius.
Ville	Localisation géographique de la mesure (ex : Douala, Yaoundé, etc.). C'est une variable catégorielle.
Interaction Pluie * Humidité	Variable dérivée obtenue par multiplication des deux variables, utilisée pour enrichir le modèle et capter des effets croisés.
Risque d'inondation	Variable cible (output) : étiquette binaire 0 ou 1 selon que la zone est jugée à risque ou non (définie selon l'analyse croisée NDWI + données météo).

❖ Utilisation des variables :

Les différentes variables de l'étude ont été exploitées à chaque étape du projet, de l'analyse exploratoire à la modélisation prédictive, en passant par la visualisation des résultats.

- ❖ **Analyse exploratoire** : Les variables climatiques (pluie, humidité, température) et l'indice NDWI ont été analysées à l'aide de statistiques descriptives, graphiques de distribution et corrélations, afin de dégager les tendances majeures.
- ❖ **Prétraitement des données** : Les données collectées ont été nettoyées et standardisées pour éliminer les erreurs et incohérences. Les techniques incluent la normalisation des valeurs, l'encodage des variables catégorielles, la création de nouvelles variables synthétiques et l'augmentation de données pour les images.
- ❖ **Modélisation IA** : Les variables tabulaires ont été utilisées avec un modèle AdaBoost pour la prédiction binaire du risque. Les images NDWI ont été fragmentées en patches et utilisées comme entrées pour un modèle de Deep Learning de type CNN.
- ❖ **Évaluation et interprétation** : Les variables ont permis d'évaluer les performances (via des métriques comme la précision, la courbe ROC, l'AUC), et d'identifier les facteurs les plus influents dans la prédiction.
- ❖ **Visualisation et alertes** : Les variables de prédiction et géographiques ont été exploitées pour générer des cartes interactives, ainsi que des messages d'alerte dans l'application.

Tableau 2: Utilisation des variables

Étape	Variables utilisées	Utilisation principale
Analyse exploratoire	pluie, humidité, température, NDWI	Histogrammes, corrélation, tendances
Prétraitement	pluie, humidité, NDWI, ville	Normalisation, encodage, variable synthétique ($pluie \times humidité$)
Modélisation AdaBoost	Toutes sauf <i>date</i>	Prédiction du risque tabulaire

Modélisation CNN	Images NDWI converties en patches	Apprentissage visuel à partir de données d'images
Évaluation du modèle	<i>risque_inondation</i> , prédictions (<i>y_pred</i>)	Calcul de précision, courbe ROC, AUC
Visualisation	pluie, humidité, NDWI, <i>risque_inondation</i> , latitude/longitude	Affichage de cartes et de zones critiques
Génération d'alertes	probabilité, latitude, longitude, ville	Identification des zones à haut risque dans l'application

2. Echantillonnage & Outils de l'étude

2.1. *Echantillonnage & Collecte des données*

L'échantillonnage dans cette étude s'appuie sur une sélection raisonnée des zones géographiques et des types de données pertinentes à l'objectif de prédiction du risque d'inondation au Cameroun. La démarche s'est voulue non probabiliste et empirique, en raison des contraintes de disponibilité des données et du temps imparti pour le projet.

❖ Population cible :

La population d'étude est constituée des zones urbaines et périurbaines du Cameroun potentiellement exposées aux inondations, en particulier celles qui présentent une fréquence élevée de précipitations et une vulnérabilité climatique ou géographique connue.

❖ Echantillon retenu :

Le choix des localités s'est porté sur six grandes régions urbaines du Cameroun, régulièrement touchées par des inondations, pour lesquelles il est possible d'obtenir des données satellites et météorologiques fiables :

DETECTION DES ZONES A RISQUE D'INONDATION A PARTIR DE DONNEES SATELLITES & METEOROLOGIQUES

Tableau 3: Ville retenue pour l'étude

Ville	Région administrative	Critères de sélection
Douala	Littoral	Forte urbanisation, proximité avec la mer, inondations fréquentes
Yaoundé	Centre	Capitale administrative, inondations urbaines récurrentes
Maroua	Extrême-Nord	Risques liés au changement climatique et au débordement du fleuve Mayo
Bafoussam	Ouest	Zones montagneuses avec glissements de terrain possibles
Bamenda	Nord-Ouest	Urbanisation sur des pentes instables
Limbe/Buea	Sud-Ouest	Zones côtières soumises aux crues et coulées de boue



Figure 3: Carte des risques d'inondations (INS, 2022)

DETECTION DES ZONES A RISQUE D'INONDATION A PARTIR DE DONNEES SATELLITES & METEOROLOGIQUES

❖ Justification de la méthode d'échantillonnage :

Le choix d'un échantillonnage raisonné est motivé par :

- ❖ La disponibilité et la qualité des données (images NDWI, données météorologiques historiques) pour ces zones.
- ❖ L'urgence et le réalisme du délai de traitement pour une étude académique.
- ❖ L'intérêt scientifique et opérationnel de ces zones pour les autorités et ONG locales.

➤ Collecte des données :

L'étude repose sur des données secondaires extraites de sources fiables, issues principalement de bases de données ouvertes, en particulier :

Tableau 4: Source de données

Source	Données collectées
NASA POWER	Données météorologiques (précipitations, humidité, température) entre 2020 et 2024
Copernicus / Sentinel-2	Images satellites multi spectrales utilisées pour le calcul de l'indice NDWI
HydroSHEDS / HydroRIVERS	Cours d'eau, fleuves et rivières géo-référencés pour les superpositions SIG
GeoBoundaries	Fichiers shapefile des limites administratives du Cameroun
Cameroun Flood Database (cmr_floodsdata)	Données historiques d'inondations signalées localement

La collecte de données s'est faite selon une procédure rigoureuse :

1. Téléchargement des images satellites Sentinel-2 via Google Earth Engine Code Editor pour les six villes ciblées.
2. Téléchargement des séries temporelles météo entre janvier 2020 et juillet 2025 (pluie, humidité, température).

3. Téléchargement de fichiers géographiques shapefiles pour les contours administratifs, rivières et localisations SIG.
4. Organisation des données dans des dossiers structurés pour faciliter les traitements Python.
5. Création manuelle d'un dataset tabulaire contenant les indicateurs calculés (moyennes météo, NDWI, classe de risque).
6. Constitution manuelle d'un mini-dataset d'images NDWI segmentées pour la modélisation CNN.

2.2. Outils de l'étude

La réalisation de ce projet a mobilisé plusieurs outils logiciels et bibliothèques Python essentiels à la fois pour la collecte, le traitement, la modélisation et la visualisation des données. Voici les principaux :



- **Python** : Langage principal de développement, utilisé pour toutes les étapes de traitement et d'analyse.



- **Streamlit** : Création de l'interface web interactive de l'application de prédiction à destination des utilisateurs finaux.



- **Folium** : Visualisation géographique des résultats sur des cartes interactives intégrées à l'application.



- **Scikit-learn** : Entraînement, évaluation et sauvegarde du modèle de machine Learning.



- **Tensorflow / Keras** : Création et entraînement du modèle de Deep Learning pour analyser automatiquement les images NDWI.



- **Rasterio** : Lecture et manipulation des images satellites Sentinel-2 au format .tif.



- **Pandas** : Manipulation des données tabulaires : nettoyage, transformation, agrégation, jointures.



- **Pillow** : Traitement d'images NDWI pour la segmentation en patches et la préparation des entrées du modèle CNN.



- **Groq** : Intégration d'un chatbot intelligent capable de répondre en temps réel à des questions liées aux inondations et à l'application.

CONCLUSION

La méthodologie adoptée dans le cadre de cette étude s'inscrit dans une logique rigoureuse, fondée sur l'exploitation de données réelles, la mobilisation d'outils technologiques avancés et l'application de techniques modernes d'intelligence artificielle. En partant d'une problématique clairement définie, l'étude a mobilisé des données satellites et météorologiques issues de sources fiables, que ce soit pour l'analyse environnementale ou pour la prédiction à partir d'indicateurs climatiques. Les étapes de prétraitement, de modélisation et d'évaluation ont été conduites selon une approche exploratoire et explicative, combinant des modèles de Machine Learning et de Deep Learning. Les outils techniques mobilisés (Python, Streamlit, TensorFlow, Folium, etc.) ont permis de construire une solution à la fois performante, interactive et adaptée aux besoins des utilisateurs ciblés, notamment les autorités locales, ONG et populations exposées.

CHAPITRE III: PRESENTATION D'ALTECHS ENGINEERING SARL ET DONNEES COLLECTEES

INTRODUCTION

Ce chapitre présente la société ALTECHS ENGINEERING SARL, structure spécialisée dans les technologies de l'information et de la communication au Cameroun. Il en décrit l'organisation, les domaines d'intervention ainsi que son rôle dans le développement de solutions numériques. La deuxième partie du chapitre est consacrée à la description des données utilisées dans le cadre de l'étude, notamment les données satellitaires, météorologiques et géographiques, en précisant leur provenance, leurs caractéristiques, ainsi que leur utilité dans l'analyse des risques d'inondation.

1. Présentation d'ALTECHS ENGINEERING SARL

Altechs ING est une entreprise de prestation de service dans le domaine des TIC, créée en 2012 au numéro de Registre du Commerce et du Crédit Mobilier RC/YAE/2020/B/1290 par son fondateur Hervé Roland MBOM LIKENG. Elle offre des services spécialisés en génie logiciel, ingénierie Web & Métier, Corporate Branding, Formation & Talk et bien d'autres.

1.1. *Les services d'ALTECHS ING*

L'entreprise Altechs Engineering propose une gamme de services axés sur les solutions digitales, le branding et le packaging. Voici une description détaillée de chaque service offert :

❖ **Service de Branding & Marketing Digital :**

Ce service vise à créer et promouvoir l'identité d'une marque à travers des canaux numériques. Il Aide les entreprises à établir une identité forte et reconnaissable tout en atteignant efficacement leur public cible via des plateformes digitales. Il inclut :

- La conception de logos et le développement de stratégies de marque.
- Le marketing sur les réseaux sociaux et d'autres tactiques de marketing numérique.
- La gestion de la présence en ligne pour accroître la visibilité et l'engagement d'une marque.

➤ **Service d'Ingénierie d'Application Web & Métier :**

Ce service se concentre sur le développement de solutions digitales personnalisées répondant aux besoins spécifiques des entreprises. Il Fournit des outils numériques robustes et adaptés pour optimiser les opérations commerciales et améliorer l'interaction avec les clients. Il comprend probablement :

- La conception, le développement et la maintenance de sites web sur mesure.
- La création d'applications métier spécialisées (par exemple, gestion des stocks, CRM).
- Le développement d'applications mobiles.

❖ **Service comptabilité :**

Gère les opérations financières liées aux travaux effectués dans les différents services, notamment les paiements et les frais de conception et de formation.

❖ **Service d'Imprimerie & Packagings :**

Ce service couvre la conception et la production de supports marketing physiques et d'emballages pour produits. Offrir des matériaux de qualité et visuellement attrayants qui renforcent l'image de marque et la présentation des produits. Il inclut :

- La conception et l'impression de brochures, cartes de visite, flyers et autres matériels promotionnels.
- La création d'emballages personnalisés pour des produits.

➤ **Formation & Talks :**

Ce service consiste à proposer des sessions éducatives, probablement sous forme d'ateliers, de séminaires ou de conférences. Former et informer les clients, partenaires ou le public sur des sujets pertinents, améliorant ainsi leurs pratiques dans les domaines d'expertise de l'entreprise. Les sujets incluent :

- Les meilleures pratiques en solutions digitales, branding ou packaging.
- Les tendances et innovations dans ces domaines.
- Le développement de compétences pour les entreprises ou les particuliers.

1.2. Localisation

Altechs ING est basée à NGOUSSO, Yaoundé V, BP 316.




Figure 4: Localisation de Altechs Engineering Sarl

1.3. Structure/Organigramme d'ALTECHS ING

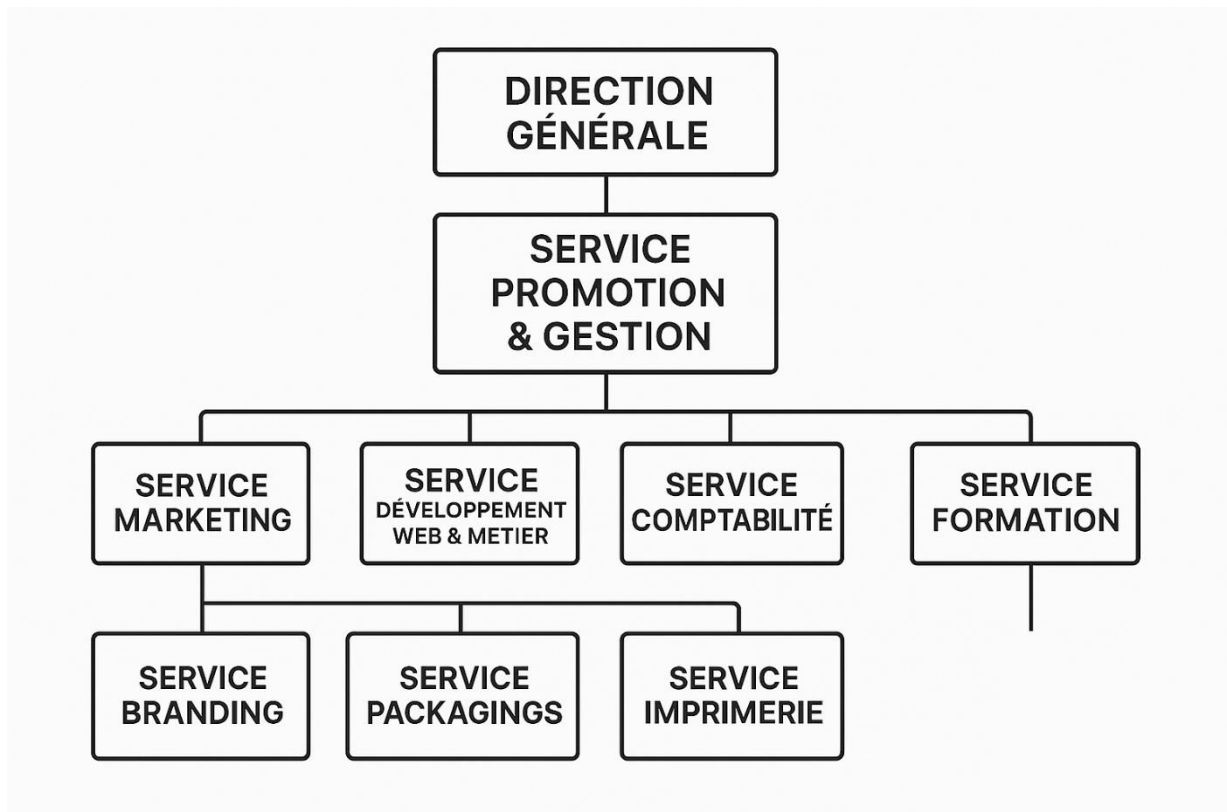


Figure 5: Organigramme Altechs Engineering SARL

2. Données collectées

2.1. Données météorologiques – NASA POWER

Les données météorologiques utilisées dans le cadre de cette étude proviennent de la plateforme NASA POWER (**P**rediction **O**f **W**orldwide **E**nergy **R**esources). Il s'agit d'un service d'accès libre développé par la NASA, permettant de télécharger des données climatiques et atmosphériques à partir de modèles de réanalyse satellitaires à haute résolution. Ces données sont accessibles via un point d'interface web ou à travers des outils d'automatisation comme Google Earth Engine.

Dans le cadre de ce projet, les données ont été extraites pour six grandes zones urbaines du Cameroun, pour une période couvrant de janvier 2025 à début juillet 2025, en cohérence avec les dates de collecte des images satellites Sentinel-2.

Les variables météorologiques collectées sont les suivantes :

- **PRECTOTCORR** (Précipitations corrigées en mm) : représente la quantité totale de précipitations journalières. Elle est un indicateur clé de la probabilité d'inondation, car une élévation brutale ou continue des précipitations peut saturer les sols et entraîner un ruissellement excessif.
- **T2M** (Température moyenne à 2 mètres en °C) : mesure la température de l'air à proximité du sol. La température influence l'évapotranspiration et peut agir indirectement sur le niveau d'humidité des sols.
- **RH2M** (Humidité relative moyenne à 2 mètres en %) : représente la quantité de vapeur d'eau présente dans l'atmosphère. Une humidité élevée couplée à de fortes pluies augmente les risques d'accumulation d'eau et donc de débordement dans les zones à faible perméabilité.

	YEAR	DOY	RH2M	T2M	PRECTOTCORR
0	2025	1	80.24	27.65	0.02
1	2025	2	77.40	27.61	0.01
2	2025	3	78.14	28.09	0.02
3	2025	4	79.92	28.05	0.06
4	2025	5	79.11	27.55	0.02

Figure 6: Aperçu des données météorologiques

Chaque observation journalière a ensuite été agrégée pour en extraire les moyennes de précipitations, d'humidité et de température sur une période de plus ou moins 15 jours autour de la date de l'image Sentinel-2 associée. Ces moyennes ont été utilisées comme variables explicatives dans les modèles de prédiction de risque développés dans ce travail. Une variable supplémentaire a été dérivée :

- **Pluie × Humidité** : une interaction construite afin d'explorer les effets combinés de la saturation de l'air et des précipitations sur le risque d'inondation.

2.2. *Données Satellites – Sentinel-2*

Les images satellitaires utilisées dans le cadre de cette étude proviennent de la mission européenne Sentinel-2, déployée par l'Agence Spatiale Européenne (ESA) dans le cadre du programme Copernicus. Cette constellation de satellites fournit des images optiques multispectrales à haute résolution (10 m à 60 m), utiles pour l'observation des surfaces terrestres, la gestion des ressources naturelles et la surveillance des risques environnementaux.

Les données ont été sélectionnées pour six grandes zones du Cameroun : Douala, Yaoundé, Maroua, Bafoussam, Bamenda et Limbé. Pour chaque ville, une image la plus récente et la plus nette possible a été téléchargée, correspondant à la période de janvier à début juillet 2025, en cohérence avec les données climatiques collectées.

Les bandes spectrales utilisées sont :

- **Bande 3 – Green (560 nm)** : sensible à la végétation, elle permet une bonne distinction entre les surfaces naturelles et les zones aquatiques ou artificielles.
- **Bande 8 – Near Infrared (842 nm)** : elle capte le rayonnement réfléchi par la végétation, l'eau et les structures minérales. En combinaison avec la bande verte, elle permet de détecter la présence d'eau à la surface.




Figure 7: Aperçu d'image NDWI traité

2.3. *Données Géographiques*

Pour appuyer l'analyse spatiale des zones à risque d'inondation, des données géographiques ont été intégrées dans cette étude. Elles permettent de contextualiser les informations satellites et météorologiques dans l'espace camerounais, en facilitant la visualisation cartographique et l'analyse géographique.

a- Frontières administratives (GeoBoundaries)

Les données administratives du Cameroun ont été obtenues à partir de GeoBoundaries, une source libre et internationale de délimitations politiques. Le fichier utilisé correspond aux frontières de niveau 1 (régions) du Cameroun, dans le shapefile nommé : *geoBoundaries-CMR-ADMI.shp*.

Chaque polygone représente une région, ce qui a permis :

- ❖ De localiser les zones d'étude ;
- ❖ De filtrer les couches spatiales (NDWI, rivières) par région ;
- ❖ De générer des cartes spécifiques par ville.

b- Réseaux hydrographiques (HydroRIVERS – Africa)

Le réseau des cours d'eau a été extrait de la base HydroSHEDS / HydroRIVERS qui fournit des shapefile hydrologiques haute résolution. Le fichier utilisé couvre l'Afrique : *HydroRIVERS_v10_af.shp*.

Il contient les polygones représentant les rivières, avec des attributs associés tels que :

- ❖ MAIN_RIV : nom du cours d'eau principal quand celui-ci est renseigné ;
- ❖ LENGTH_KM : longueur totale de la rivière ;
- ❖ DIS_AV_CMS : débit moyen estimé.

L'intégration de ces données a permis :

- ❖ De superposer les rivières aux cartes NDWI ;
- ❖ D'identifier les zones humides proches des rivières (risques plus élevés) ;
- ❖ D'enrichir la visualisation géographique des vulnérabilités.

2.4. Données historiques

Pour renforcer l'aspect contextuel et valider les corrélations entre les zones identifiées comme vulnérables par l'analyse IA et les événements réels, un jeu de données historiques sur les inondations au Cameroun a été intégré. Ce fichier a été collecté à partir de sources ouvertes et agrégées soit des rapports gouvernementaux, alertes OCHA, données de la base EM-DAT et plateformes citoyennes. Chaque ligne correspond à un événement d'inondation, avec les informations suivantes :

- ❖ Date de l'incident ;
- ❖ Région ou ville concernée ;
- ❖ Nombre estimé de personnes affectées ;
- ❖ Niveau de sévérité ;
- ❖ Description succincte de l'événement.

L'intégration de ces données a permis d'évaluer la pertinence des prédictions IA en comparant les résultats avec les événements passés et de justifier le choix des villes ciblées dans l'étude.

CONCLUSION

Ce chapitre a permis de présenter de manière structurée la structure d'accueil de l'étude, ALTECHS ENGINEERING SARL, en mettant en lumière son domaine d'intervention dans l'innovation technologique et son intérêt croissant pour les solutions d'intelligence artificielle appliquées aux problématiques environnementales. L'ensemble des données collectées a également été décrit, qu'il s'agisse de données satellitaires, météorologiques, géographiques ou encore historiques. Ces différentes sources de données ont servi de fondement à l'analyse et à la mise en œuvre des approches IA et cartographiques dans les chapitres suivants. Leur diversité et leur complémentarité renforcent la robustesse des résultats, en croisant à la fois des mesures environnementales précises, des informations spatiales et des antécédents réels d'inondations.

**CHAPITRE IV : DIAGNOSTIC DE LA SITUATION ET
PROPOSITION D'INTERVENTION**

INTRODUCTION

Les inondations représentent un risque environnemental croissant au Cameroun, affectant chaque année de nombreuses zones urbaines et rurales. Ces catastrophes naturelles provoquent d'importants dégâts matériels, perturbent les activités économiques et mettent en danger la vie des populations. Face à cette menace récurrente, l'intégration de l'intelligence artificielle (IA) dans les dispositifs de surveillance et de prévention des inondations offre une solution innovante et prometteuse. Ce chapitre présente une analyse de la situation observée, propose une intervention fondée sur l'IA, et examine la faisabilité de sa mise en œuvre sur le plan technique, économique, social et environnemental.

1. Présentation et analyse de la situation

1.1. *Analyse des hypothèses*

Au début de cette étude, plusieurs hypothèses ont été formulées afin de guider l'approche méthodologique adoptée. L'analyse des résultats issus des traitements satellitaires, des données météorologiques et des modèles d'intelligence artificielle permet de confronter ces hypothèses à la réalité des observations.

➤ **Hypothèse générale :**

L'intelligence artificielle permet de détecter efficacement les zones à risque d'inondation à partir de données satellitaires et météorologiques au Cameroun. Grâce à l'intégration d'un modèle de machine Learning et d'un modèle de Deep Learning, il a été possible de prédire les zones à risque avec une précision satisfaisante, en exploitant notamment les indicateurs NDWI, les précipitations, l'humidité et la température. L'application Streamlit développée illustre cette capacité à faire de la prédiction opérationnelle.

➤ **Hypothèse spécifique 1 :**

Les données météorologiques (pluie, humidité, température) peuvent contribuer à l'identification des zones à risque. L'analyse statistique a montré une corrélation notable entre les zones humides à NDWI élevé et des épisodes de forte précipitation, renforcée par

l'humidité relative. Ces données se sont révélées pertinentes dans la construction du modèle AdaBoost.

➤ **Hypothèse spécifique 2 :**

L'analyse des images satellitaires par Deep Learning permet d'identifier les zones inondables à partir de l'indice NDWI. Le modèle CNN entraîné à partir de patches extraits d'images NDWI a permis de classer les zones selon leur risque avec une performance prometteuse. Les résultats ont mis en évidence une détection efficace des zones aquatiques ou à forte saturation en eau. Combiné à une application combinant l'IA et une interface conviviale peut faciliter la diffusion de l'information aux acteurs locaux

1.2. Limites et difficultés

Bien que les résultats obtenus soient encourageants, plusieurs limites et difficultés ont été rencontrées au cours de cette étude, tant sur le plan technique que contextuel.

➤ **Limitations des données :**

- ❖ **Accès restreint à des jeux de données historiques fiables :** Les données météorologiques disponibles sur NASA POWER sont globales et ne sont pas toujours précises à l'échelle locale. Cela a pu influencer la finesse des prédictions.
- ❖ **Qualité et couverture des images satellites :** Les images Sentinel-2 utilisées couvraient une période relativement courte (les 6 derniers mois), limitant l'analyse temporelle approfondie de la dynamique des zones à risque.
- ❖ **Manque de données labellisées :** Pour entraîner le modèle de Deep Learning, il a fallu constituer manuellement un dataset à partir des NDWI, faute de base d'images annotées sur les inondations au Cameroun.

➤ **Contraintes techniques :**

- ❖ **Capacités de traitement limitées :** Le traitement des images .tif, l'extraction d'indices (NDWI) et l'entraînement des modèles CNN ont nécessité des ressources computationnelles importantes, rendant certaines tâches longues et sensibles aux erreurs.

- ❖ **Difficulté d'intégration des formats** : La gestion des formats géographiques (shapefiles, rasters) et leur superposition avec les prédictions a exigé une bonne maîtrise des outils SIG et des bibliothèques Python spécifiques.
 - ❖ **Accessibilité limitée à certaines plateformes** : Des difficultés d'accès aux portails de données (Earth Engine, HydroSHEDS, etc.) ont parfois ralenti le processus de collecte et de traitement des données.
 - ❖ **Charge cognitive élevée** : La diversité des outils mobilisés (machine Learning, Deep Learning, traitement géospatial, développement d'application web) a exigé une courbe d'apprentissage rapide.
- **Contraintes temporelles** :

Le projet devait être mené en un temps restreint, ce qui a limité la possibilité de tests approfondis, d'ajustements hyper paramétriques poussés ou de déploiement avancé.

1.3. Proposition d'un modèle et prospective

➤ **Modèle de détection proposé**

Face aux enjeux de prévision des risques d'inondation, une architecture hybride combinant machine Learning et Deep Learning a été développée dans ce projet.

- **Modèle AdaBoost** : Ce modèle a été entraîné sur un dataset tabulaire constitué de plusieurs variables météorologiques (NDWI moyen, précipitations, température, humidité, etc.) issues des données NASA POWER. Il permet de prédire la classe de risque à partir de mesures numériques.
- **Modèle CNN** : Le modèle de Deep Learning a été entraîné sur des fragments d'images NDWI générés à partir d'images satellites Sentinel-2. Il identifie visuellement les zones potentiellement inondables en analysant leur texture, structure hydrologique et teneur en végétation.

Cette approche bimodale permet de croiser les données physiques et visuelles, améliorant ainsi la robustesse du système global.

➤ **Intégration dans une application Streamlit :**

Les deux modèles ont été intégrés dans une application web interactive conçue avec Streamlit, permettant :

- La prédiction en temps réel par chargement d'images NDWI ou saisie de données météo.
- La visualisation des risques sur carte avec Folium.
- L'interaction via chatbot avec Livu AI.
- L'accès à des recommandations pratiques en cas de détection de zones sensibles.

➤ **Perspectives d'évolution**

Plusieurs pistes pourraient être envisagées pour améliorer et étendre cette solution :

- **Extension géographique** : Appliquer la méthodologie à d'autres zones du Cameroun, voire à l'échelle sous régionale.
- **Amélioration de l'étiquetage** : Constitution d'un dataset supervisé en partenariat avec des autorités locales ou via crowdsourcing.
- **Utilisation de séries temporelles** : Intégrer des données temporelles pour suivre l'évolution des risques dans le temps.
- **Ajout de capteurs IoT en temps réel** : Croiser les prédictions IA avec des mesures physiques issues de capteurs sur le terrain.
- **Déploiement mobile** : Développement d'une version mobile de l'application pour un usage terrain par les populations ou les services d'intervention.

2. Intervention proposée et justification

2.1. Objectifs de l'intervention – Projet envisagé

2.1.1. Objectif général

L'objectif de cette intervention est de développer une solution numérique intelligente de prédiction des zones à risque d'inondation au Cameroun, en exploitant des données satellites

et météorologiques à travers des techniques d'intelligence artificielle, afin de renforcer la capacité d'anticipation et de réponse des parties prenantes aux catastrophes naturelles.

2.1.2. Objectifs spécifiques

- ❖ **Élaborer un modèle de Machine Learning** permettant de prédire la présence de zones à risque à partir des variables telles que l'humidité, la pluie, la température et le NDWI moyen.
- ❖ **Mettre en place un modèle de Deep Learning** capable d'interpréter automatiquement des images NDWI fragmentées pour détecter des zones inondables.
- ❖ **Intégrer les deux modèles prédictifs** dans une interface interactive via l'outil Streamlit, permettant aux utilisateurs de charger des images ou de saisir des données météo.
- ❖ **Générer des visualisations interactives et des alertes intelligentes**, facilitant la compréhension et la réaction rapide des autorités locales et des communautés vulnérables.

2.2. Composantes de l'intervention envisagée

2.2.1. Composantes humaines

La mise en œuvre de cette intervention repose sur une collaboration entre plusieurs profils techniques et non techniques :

- ❖ **Spécialistes en géomatique** : Traitement des images satellites (NDWI, rasterisation, SIG).
- ❖ **Développeurs IA / Data Scientists** : Conception, entraînement et évaluation des modèles Machine Learning et Deep Learning.
- ❖ **Développeurs web / Fullstack** : Intégration des modèles dans l'application Streamlit, déploiement.
- ❖ **Responsables d'analyse météo** : Suivi et validation de la cohérence des données climatiques utilisées.

- ❖ **Bénéficiaires / Collectivités locales** : Utilisation finale de l'outil pour la prise de décision.

2.2.2. Composantes techniques

Cette composante regroupe les infrastructures matérielles et les outils techniques nécessaires :

- ❖ **Ordinateur avec GPU ou accès à un environnement cloud** : Entraînement efficace du modèle CNN sur les images NDWI.
- ❖ **Serveur ou instance de déploiement** : Hébergement de l'application Streamlit pour un accès en ligne.
- ❖ **Connexion internet stable** : Accès aux jeux de données en ligne (NASA POWER, Sentinel-2).
- ❖ **Stockage local ou cloud** : Sauvegarde des images NDWI, des modèles *.pkl* et *.h5*.

2.2.3. Composantes logicielles

L'ensemble du projet repose sur une pile logicielle cohérente, open-source et bien adaptée aux tâches de traitement de données et de modélisation IA :

Tableau 5: Outils Logiciels

Outil / Librairie	Rôle principal
Python	Langage de programmation principal
Pandas / NumPy	Manipulation et transformation des données tabulaires
Rasterio	Lecture et traitement des images satellites (NDWI)
TensorFlow / Keras	Construction et entraînement du modèle CNN
Scikit-learn	Entraînement du modèle AdaBoost, évaluation, pipelines
Streamlit	Développement de l'interface interactive pour les utilisateurs finaux
Pillow	Chargement, redimensionnement et découpage des images

Folium	Affichage de cartes interactives pour localiser les zones à risque
Groq	Intégration d'un assistant IA (Livu) dans l'application

2.3. *Périmètre d'intervention, contenu de la solution et stratégies d'actions*

2.3.1. *Périmètre d'intervention*

L'intervention cible spécifiquement les zones urbaines du Cameroun exposées aux risques d'inondation, avec une attention particulière portée sur six grandes villes ayant une fréquence notable d'événements hydrométéorologiques extrêmes :

- ❖ **Douala**
- ❖ **Yaoundé**
- ❖ **Maroua**
- ❖ **Bafoussam**
- ❖ **Bamenda**
- ❖ **Limbé/Buea**

Ces localités ont été choisies en raison de leur forte densité urbaine, de leur fréquence d'inondation supérieur à celle des autres villes et de la disponibilité de données satellites et météorologiques fiables.

Région	2017	2018	2019
Adamaoua	0	0	0
Centre	1	1	1
Est	0	0	0
Extrême-Nord	1	1	4
Littoral	2	1	1
Nord	0	0	0
Nord-Ouest	3	0	0
Ouest	2	0	2
Sud	0	0	0
Sud-Ouest	3	1	0
Cameroun	12	4	8

Figure 8: Récapitulatif des données issues du journal des catastrophes (MINAT)

2.3.2. Contenu de la solution & Stratégies d'actions

a. Conception d'un modèle de machine Learning de détection des risques d'inondations

➤ Collecte et importation des données :

La première phase a consisté à rassembler des données issues de plusieurs sources fiables, notamment des données climatiques extraites depuis l'API de la NASA POWER, incluant :

- NDWI moyen (indice de végétation lié à l'humidité),
- Précipitations (pluie en mm),
- Température moyenne,
- Humidité moyenne.

Les données ont été stockées sous format CSV et importées dans un environnement Python à l'aide de bibliothèques telles que pandas et NumPy.

```
df = pd.read_csv("data/dataset_risque_inondation.csv")
print("Aperçu des données :")
df.head()
```

✓ 0.1s Python

Aperçu des données :

	ville	date	ndwi_moyen	pluie_mm	humidite_moyenne	temperature_moyenne	risque_inondation
0	Douala	2025-06-21	-0.235254	15.068583	90.930791	26.134760	1
1	Douala	2025-06-24	-0.222814	16.306288	89.348683	24.619864	1
2	Douala	2025-06-19	-0.205064	17.626787	86.561341	25.522753	1
3	Douala	2025-06-17	-0.224863	13.693370	91.921509	24.956204	1
4	Douala	2025-06-21	-0.236004	16.148600	90.656551	24.531552	1

Figure 9: Aperçu des données et chargement du dataset

➤ Prétraitement et analyse exploratoire des données :

Cette étape a permis d'assurer la qualité et la pertinence des données avant leur utilisation pour l'apprentissage automatique. Les tâches menées sont les suivantes :

- ❖ **Statistiques descriptives** : analyse de la moyenne, médiane, écart-type, valeurs extrêmes pour chaque variable.

DETECTION DES ZONES A RISQUE D'INONDATION A PARTIR DE DONNEES SATELLITES & METEOROLOGIQUES

	ndwi_moyen	pluie_mm	humidite_moyenne	temperature_moyenne	risque_inondation
count	150.000000	150.000000	150.000000	150.000000	150.000000
mean	-0.206143	11.234866	81.432632	24.698861	0.666667
std	0.031209	4.883326	14.161034	3.230853	0.472984
min	-0.273541	0.000000	47.541932	19.858960	0.000000
25%	-0.230111	8.412754	84.154729	22.149787	0.000000
50%	-0.208954	11.893085	86.648408	24.229002	1.000000
75%	-0.179276	14.707300	89.351628	26.020167	1.000000
max	-0.143315	21.688929	94.387470	32.241081	1.000000

Figure 10: Statistiques descriptives du jeu de données

- ❖ **Vérification des valeurs manquantes** : détection et traitement des données manquantes, notamment par suppression ou remplissage. Dans notre cas, aucune valeur manquante n'a été détecté.

```
Vérification des valeurs manquantes :
ville                                0
date                                0
ndwi_moyen                          0
pluie_mm                            0
humidite_moyenne                    0
temperature_moyenne                0
```

Figure 11: Valeur manquantes

- ❖ **Analyse de la distribution de la variable cible** (risque_inondation) : déséquilibre des classes analysées pour adapter le modèle.

```
# Distribution de la variable cible
plt.figure(figsize=(6, 4))
sns.countplot(x='risque_inondation', data=df)
plt.title("Distribution des classes de risque d'inondation")
plt.show()
```

✓ 1.0s




Figure 12: Distribution des classes

- ❖ **Création de variables dérivées** : par exemple une variable `pluie_humidite_interaction` a été introduite pour mieux capturer l'effet combiné de ces facteurs.

```
# 2. Feature Engineering
df['pluie_humidite_interaction'] = df['pluie_mm'] * df['humidite_moyenne']
```

✓ 0.0s

Figure 13: Création de la variable "Pluie_Humidité"

➤ Construction du modèle :

- ❖ **Pipeline de traitement** : mise en place d'un pipeline ColumnTransformer + AdaBoost avec gestion automatisée des variables catégorielles (ville) et numériques.

```
# Pipeline de preprocessing
preprocessor = ColumnTransformer(
    transformers=[
        ('num', StandardScaler(), numeric_cols),
        ('cat', OneHotEncoder(drop='first', sparse_output=False), categorical_cols)
    ])
✓ 0.0s
```

Figure 14: Pipeline Preprocessing

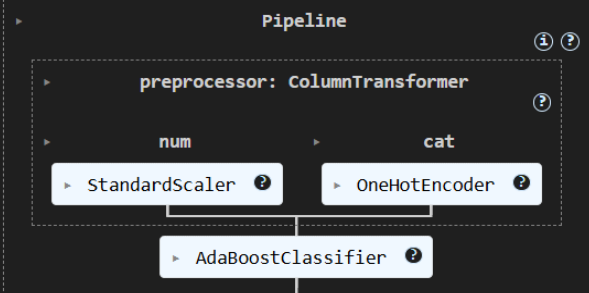
- ❖ Séparation des données en jeu d'entraînement (80%) et de test (20%) à l'aide de `train_test_split`.

```
# Création du pipeline avec AdaBoost
pipeline = Pipeline(steps=[
    ('preprocessor', preprocessor),
    ('classifier', AdaBoostClassifier())
])
✓ 0.0s
```

Generate + Code + Markdown

```
# Division des données
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
✓ 0.0s
```

```
# Entraînement initial
pipeline.fit(X_train, y_train)
✓ 0.2s
```



The diagram illustrates the structure of the Pipeline. It is a dashed box labeled 'Pipeline' containing three main components: 'preprocessor: ColumnTransformer', 'num', and 'cat'. The 'preprocessor' component is further detailed as containing 'num' and 'cat' sub-components. The 'num' sub-component contains a 'StandardScaler' box, and the 'cat' sub-component contains a 'OneHotEncoder' box. Both 'StandardScaler' and 'OneHotEncoder' boxes have a question mark icon. Below these two sub-components, there is an 'AdaBoostClassifier' box, also with a question mark icon. Arrows indicate the flow of data from the 'num' and 'cat' sub-components into the 'AdaBoostClassifier' box.

Figure 15: Pipeline AdaBoost Classifier

DETECTION DES ZONES A RISQUE D'INONDATION A PARTIR DE DONNEES SATELLITES & METEOROLOGIQUES

➤ Evaluation des performances :

```

Classification Report (modèle initial) :

```

	precision	recall	f1-score	support
0	1.00	0.94	0.97	18
1	0.98	1.00	0.99	41
accuracy			0.98	59
macro avg	0.99	0.97	0.98	59
weighted avg	0.98	0.98	0.98	59

Figure 16: Evaluation de AdaBoost Classifier

➤ Comparaison des modèles :

	Model	Accuracy	AUC	Recall	Prec.	F1	Kappa	MCC	TT (Sec)
nb	Naive Bayes	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	0.0100
ridge	Ridge Classifier	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	0.0140
rf	Random Forest Classifier	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	0.0330
lda	Linear Discriminant Analysis	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	0.0090
et	Extra Trees Classifier	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	0.0350
ada	Ada Boost Classifier	0.9809	1.0000	0.9857	0.9875	0.9856	0.9575	0.9612	0.0200
lr	Logistic Regression	0.9700	1.0000	0.9857	0.9750	0.9790	0.9256	0.9329	0.4750
lightgbm	Light Gradient Boosting Machine	0.9627	0.9774	0.9714	0.9732	0.9714	0.9182	0.9219	0.0260
knn	K Neighbors Classifier	0.9527	0.9905	0.9857	0.9500	0.9656	0.8872	0.8976	0.1890
dt	Decision Tree Classifier	0.9509	0.9548	0.9429	0.9857	0.9626	0.8903	0.8955	0.0100
gbc	Gradient Boosting Classifier	0.9509	0.9613	0.9429	0.9857	0.9626	0.8903	0.8955	0.0190
svm	SVM - Linear Kernel	0.8582	0.9548	0.9429	0.8836	0.9014	0.6300	0.6468	0.0100
dummy	Dummy Classifier	0.6682	0.5000	1.0000	0.6682	0.8007	0.0000	0.0000	0.0080
qda	Quadratic Discriminant Analysis	0.3318	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0120

Figure 17: Comparaison des modèles avec Pycaret

b. Conception d'un modèle de Deep Learning CNN de détection des zones à risques d'inondation

➤ Constitution du dataset image NDWI :

DETECTION DES ZONES A RISQUE D'INONDATION A PARTIR DE DONNEES SATELLITES & METEOROLOGIQUES

Le processus a débuté par la création d'un dataset image basé sur l'indice NDWI. Les étapes de constitution ont débuté avec le téléchargement d'images satellites Sentinel-2 depuis des plateformes ouvertes, dans notre cas il s'agit de Copernicus et EO Browser. On procède ensuite au traitement NDWI appliqué à chaque image à l'aide de la librairie Rasterio, en combinant les bandes verte (B3) et proche infrarouge (B8).

```
path = ".\\data\\Sentinel2_Douala.tif"

# Ouverture avec rasterio
with rasterio.open(path) as src:
    green = src.read(3).astype('float32') # B3 : Vert
    nir = src.read(8).astype('float32')   # B8 : Infrarouge proche

# Éviter la division par zéro
ndwi = np.where(
    (green + nir) == 0,
    0,
    (green - nir) / (green + nir)
)
```

Figure 18: Chargement des images et calcul de l'indice NDWI

On passe ensuite à une fragmentation automatique de chaque image en patches de 64×64 pixels pour créer un ensemble d'échantillons utilisables en apprentissage profond.



Figure 19: Aperçu du dataset image

Ensuite on passe par une classification manuelle des patches :

- Class_1 : patch contenant des zones potentiellement inondées.
- Class_0 : patch sans risque d'inondation apparent.

Cette méthode a permis de constituer une base d'images équilibrée et adaptée à l'entraînement d'un modèle CNN.

➤ Prétraitement des images et augmentation des données :

Avant l'entraînement, les images ont été préparées et enrichies pour améliorer la robustesse du modèle :

- **Redimensionnement** à 64x64 pixels et **normalisation** des valeurs entre 0 et 1.
- **Augmentation de données** via ImageDataGenerator :
 - Rotations aléatoires,
 - Translations horizontales et verticales,
 - Inversions horizontales.

```
# 1. Ajout de l'augmentation de données pour l'entraînement
train_datagen = ImageDataGenerator(
    rescale=1./255,
    rotation_range=20,           # Rotation aléatoire jusqu'à 20°
    width_shift_range=0.2,      # Décalage horizontal jusqu'à 20%
    height_shift_range=0.2,     # Décalage vertical jusqu'à 20%
    horizontal_flip=True,       # Flip horizontal
    validation_split=0.2
)
✓ 0.0s

# Pour la validation, on ne fait que normaliser
val_datagen = ImageDataGenerator(
    rescale=1./255,
    validation_split=0.2
)
✓ 0.0s
```

Figure 20: Prétraitement des images

Cela a permis de simuler davantage de scénarios et d'éviter le sur apprentissage.

➤ Conception de l'architecture CNN :

Le modèle Deep Learning est basé sur un **réseau de neurones convolutif (CNN)** avec la structure suivante :

- **3 blocs convolution + max pooling** pour extraire progressivement les motifs visuels (zones humides, reflets d'eau, etc.).
- **Flatten layer** pour aplatir les caractéristiques extraites.
- **Dense layers** (couches entièrement connectées) pour effectuer la classification finale.
- Activation **sigmoïde** pour produire une sortie binaire (risque ou non).

L'entraînement a été réalisé avec :

- Optimiseur **Adam**
- Fonction de perte **binary_crossentropy**
- **EarlyStopping** pour interrompre l'apprentissage en cas de stagnation en validation.

```
# 2. Architecture CNN
model = models.Sequential([
    layers.Conv2D(32, (3, 3), activation='relu', input_shape=(img_size, img_size, 3)),
    layers.MaxPooling2D((2, 2)),
    layers.Conv2D(64, (3, 3), activation='relu'),
    layers.MaxPooling2D((2, 2)),
    layers.Conv2D(128, (3, 3), activation='relu'),
    layers.MaxPooling2D((2, 2)),
    layers.Flatten(),
    layers.Dense(64, activation='relu'),
    layers.Dense(1, activation='sigmoid') # Binaire
])

model.compile(optimizer='adam', loss='binary_crossentropy', metrics=['accuracy'])
✓ 0.0s

# 3. Ajout de EarlyStopping
early_stop = EarlyStopping(monitor='val_loss', patience=3, restore_best_weights=True)
✓ 0.0s

# Entraînement avec EarlyStopping
history = model.fit(
    train_generator,
    validation_data=val_generator,
    epochs=50, # Nombre d'époques plus élevé, EarlyStopping arrêtera si nécessaire
    callbacks=[early_stop]
)
```

Figure 21: Aperçu de l'architecture du modèle CNN

c. Présentation de l'application

L'application Livu est une plateforme web interactive développée avec le Framework Streamlit. L'application est structurée en cinq modules principaux, accessibles via une barre

latérale intuitive, avec une sélection de ville et une option de bascule entre le français et l'anglais pour une accessibilité accrue.

1. Accueil

Le module d'accueil présente l'application Livu à travers un design visuel attrayant, comprenant un titre centré, une animation Lottie et une image qui nous met dans le contexte de l'inondation. Une section textuelle décrit les objectifs de l'application, en mettant en avant les quatre fonctionnalités principales : prédiction par image NDWI, prédiction par données météorologiques, carte interactive, et recommandations. Chaque fonctionnalité est brièvement introduite avec des icônes pour une navigation visuelle claire. Ce module sert de point d'entrée engageant, facilitant l'orientation des utilisateurs et renforçant l'identité visuelle de l'application.



Figure 22: Accueil de Livu AI

2. Prédiction par Image NDWI

Ce module permet aux utilisateurs de charger une image satellite NDWI au format PNG ou JPEG pour détecter les zones à risque d'inondation. L'image est décomposée en patches de taille 64x64 pixels, qui sont ensuite normalisés et passés à notre modèle CNN pré-entraîné.

DETECTION DES ZONES A RISQUE D'INONDATION A PARTIR DE DONNEES SATELLITES & METEOROLOGIQUES

Les prédictions sont effectuées sur chaque patch, avec un seuil de 0.5 pour distinguer les zones à risque des zones non à risque. Les résultats incluent :

- Le nombre total de patches générés.
- La forme des patches pour vérification.
- Le nombre de patches identifiés comme à risque.
- La probabilité moyenne de risque sur l'ensemble des patches.
- Une visualisation d'un patch aléatoire pour illustrer le processus.

En cas de probabilité moyenne supérieure à 70 %, une alerte est générée, recommandant des actions immédiates avec un message copiable pour informer les populations concernées. Ce module offre une analyse visuelle rapide et automatisée des images NDWI, essentielle pour identifier les zones inondables dans des contextes où les données satellites sont disponibles.

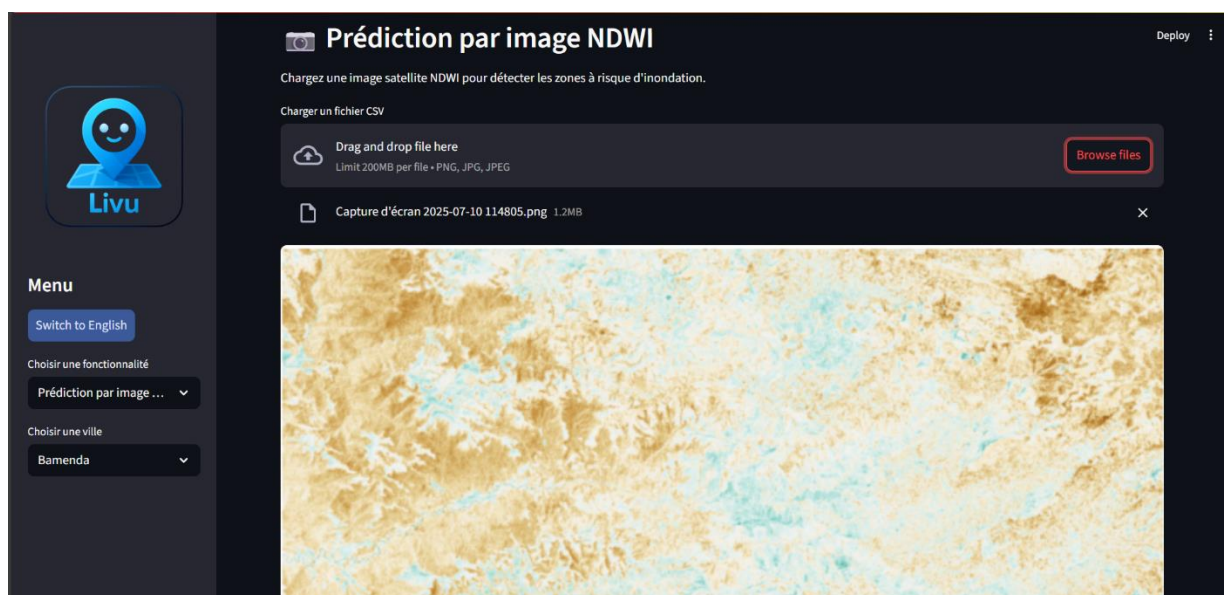


Figure 23: Prédiction par image satellite

3. Prédiction par Données Météorologiques

Ce module permet de prédire le risque d'inondation à partir de données météorologiques, soit en saisissant manuellement les paramètres, soit en chargeant un fichier CSV. Il est divisé en deux sous-modules :

DETECTION DES ZONES A RISQUE D'INONDATION A PARTIR DE DONNEES SATELLITES & METEOROLOGIQUES

- **Sans dataset** : L'utilisateur ajuste manuellement les paramètres (NDWI moyen, pluie en mm, température moyenne en °C, humidité moyenne en %) via des sliders. La ville est sélectionnée dans la barre latérale. Les données sont structurées dans un DataFrame avec les colonnes *ville*, *ndwi_moyen*, *pluie_mm*, *temperature_moyenne*, *humidite_moyenne*, et *pluie_humidite_interaction* (calculée comme le produit de *pluie_mm* et *humidite_moyenne*). Le modèle AdaBoost effectue la prédiction, et les résultats indiquent si la zone est à risque (classe 1) ou non (classe 0), avec la confiance associée.



Figure 24: Prédiction sans dataset

- **Avec dataset** : L'utilisateur charge un fichier CSV contenant les colonnes nécessaires. Une visualisation des données est proposée via des graphiques interactifs Plotly, avec une coloration selon le risque d'inondation. Les prédictions sont effectuées sur l'ensemble du dataset, et les résultats sont affichés dans un tableau avec les colonnes *prediction* et *probability*. Une carte interactive est générée si les colonnes latitude et longitude sont présentes, montrant les zones à risque (en rouge) ou non (en vert).

DETECTION DES ZONES A RISQUE D'INONDATION A PARTIR DE DONNEES SATELLITES & METEOROLOGIQUES



Figure 25: Prédiction Avec Dataset

Ce module combine flexibilité (saisie manuelle ou dataset) et visualisation avancée, permettant une analyse détaillée des facteurs météorologiques contribuant aux inondations.

4. Carte Interactive

Ce module permet de charger un fichier CSV contenant les colonnes latitude, longitude, et pluie_mm pour afficher une carte interactive des zones où les précipitations dépassent 25 mm. La carte, générée avec Folium, est centrée sur la moyenne des coordonnées du dataset et affiche des marqueurs rouges pour chaque point correspondant à une forte pluie. Si le dataset ne contient pas les colonnes nécessaires, un message d'erreur informe l'utilisateur. Ce module offre une visualisation géospatiale claire, essentielle pour les décideurs qui souhaitent identifier les zones critiques à l'échelle régionale.

DETECTION DES ZONES A RISQUE D'INONDATION A PARTIR DE DONNEES SATELLITES & METEOROLOGIQUES

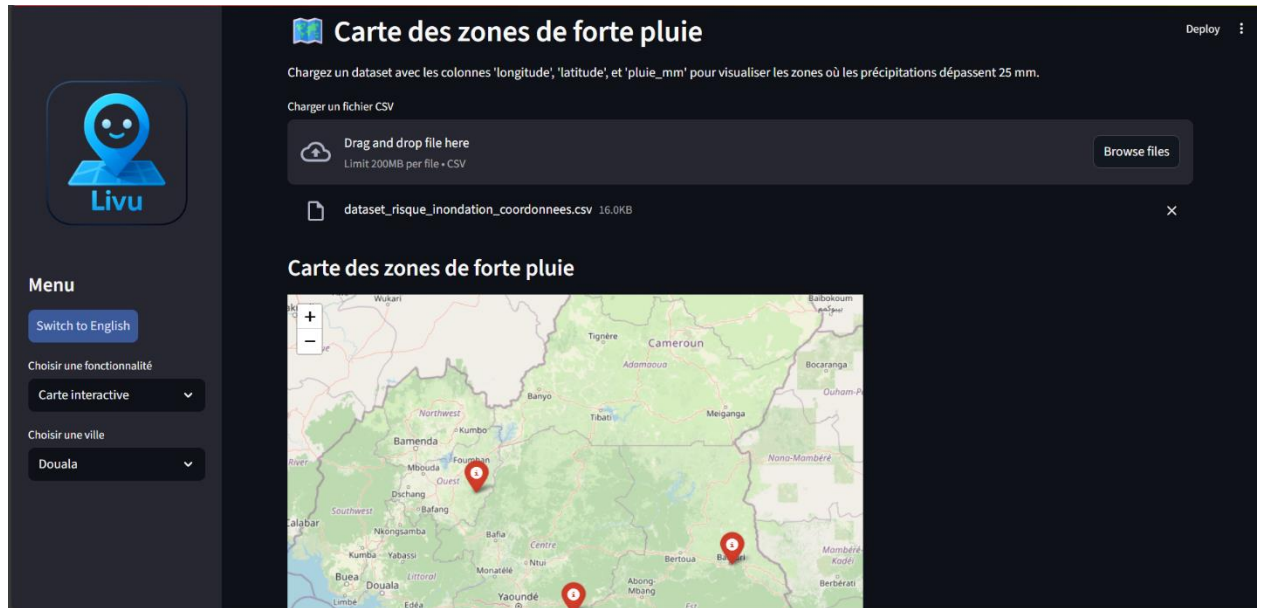


Figure 26: Aperçu des zones à fortes pluies

5. Recommandations Pratiques

Ce module traduit les prédictions en actions concrètes, rendant l'application directement applicable pour la gestion des risques.

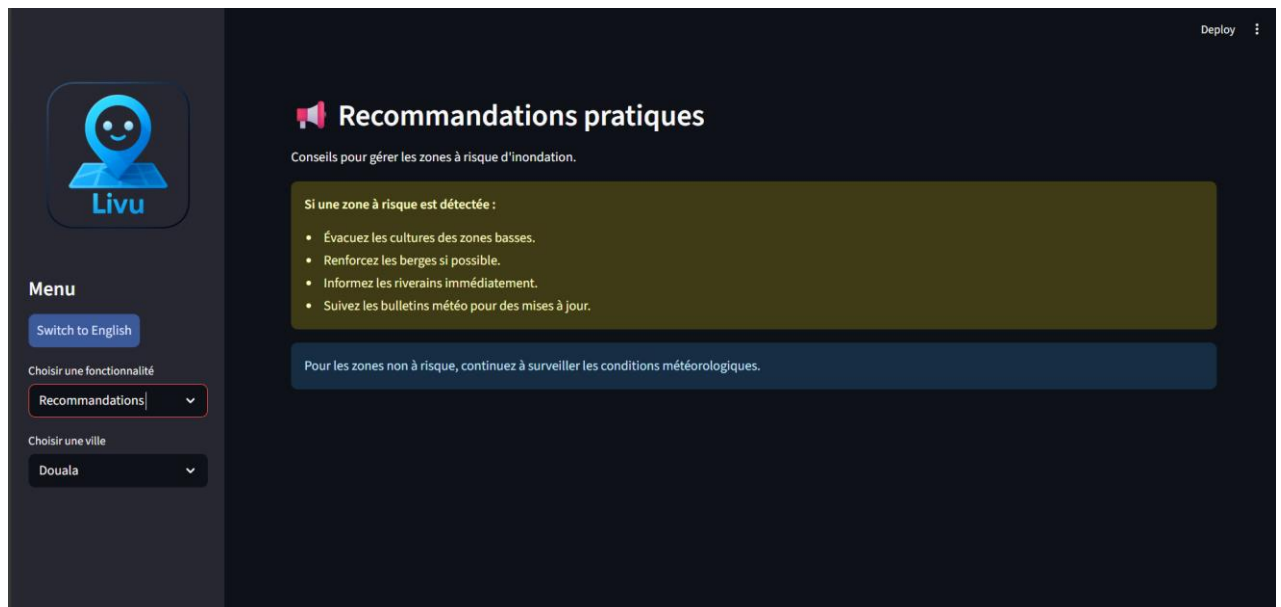


Figure 27: Recommandations pratiques

6. Livu AI (Chatbot)

Le module Livu AI est un chatbot basé sur l’API Groq, permettant aux utilisateurs de poser des questions en langage naturel. Les échanges sont enregistrés dans un historique et affichés avec une mise en forme claire. Une animation Lottie accompagne visuellement le module. Il répond uniquement aux questions qui ont un lien avec le sujet d’étude et l’application.

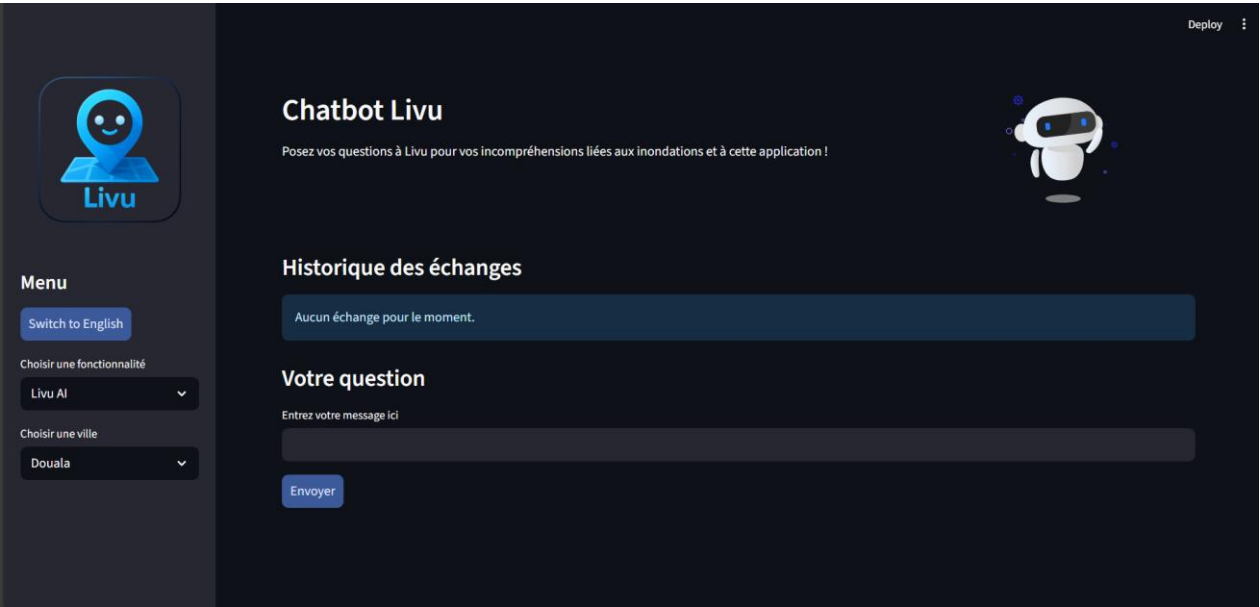


Figure 28: Chatbot Livu AI

2.4. Etude de la faisabilité

Tableau 6: Faisabilité

Volet	Éléments évalués	Observations	Coûts estimés
Économique	Accès aux données	Données Sentinel-2, NASA POWER et NDWI	500.000 FCFA

DETECTION DES ZONES A RISQUE D'INONDATION A PARTIR DE DONNEES SATELLITES & METEOROLOGIQUES

	Outils de développement	Python, TensorFlow, Scikit-learn, Streamlit, etc.	200.000 FCFA
	Infrastructure de traitement	Ordinateur personnel ou serveur local	750.000 FCFA
	Hébergement web	Streamlit Cloud	50 000 FCFA / an
	Développeur	Développement de l'application, apport de mise à jour	2.000.000 FCFA
	TOTAL	Dépense total de la première année	3.500.000 FCFA

CONCLUSION

L'analyse de la situation actuelle met en évidence la vulnérabilité de plusieurs zones du Cameroun face aux inondations, en raison de facteurs climatiques, géographiques et urbains. Face à ce constat, une solution intégrant l'intelligence artificielle a été proposée, combinant la détection par image NDWI et l'analyse prédictive à partir des données météorologiques. Cette intervention repose sur des composantes techniques solides tels que des modèles IA et une application Streamlit, des données fiables et accessibles, ainsi qu'une approche centrée sur la prévention et l'alerte. L'étude de faisabilité confirme la viabilité du projet sur les plans économique, technique, social et environnemental. Elle démontre que cette approche peut être déployée à moindre coût tout en répondant à des besoins critiques de gestion des risques.

CONCLUSION GENERALE

Les inondations constituent un défi majeur pour de nombreuses régions du monde, exacerbées par le changement climatique et l'urbanisation rapide. Ce travail a démontré comment la combinaison de données satellites et de données météorologiques historiques peut être exploitée, au moyen de l'intelligence artificielle, pour identifier et anticiper les zones à risque d'inondation. La phase de faisabilité a confirmé la viabilité économique, sociale et technique.

En conclusion, ce projet illustre la valeur ajoutée des technologies d'intelligence artificielle et de télédétection pour la gestion proactive des risques naturels. L'application développée offre un outil opérationnel aux collectivités locales, ONG et services d'urgence, renforçant leur capacité à prévoir et à limiter les effets dévastateurs des inondations. Elle ouvre également la voie à de futures extensions : intégration d'autres types de données, déploiement en continu avec des flux temps réel, ou adaptation à d'autres aléas climatiques.

Ce mémoire montre ainsi qu'une approche interdisciplinaire, alliant géomatique, science des données et développement logiciel, peut contribuer de manière significative à la résilience des territoires face aux catastrophes naturelles.

REFERENCES BIBLIOGRAPHIQUES

- Banque mondiale. (2021). *Rapport sur les impacts des inondations mondiales*. <https://www.worldbank.org/>
- Ramiaramananana, F. N., & Teller, J. (2021). *Urbanisation and floods in Sub-Saharan Africa: Spatiotemporal dynamics and socio-economic drivers in Cameroon*. [Source non précisée].
- IPCC. (2021). *Sixth Assessment Report: Climate Change 2021 – The Physical Science Basis*. Cambridge University Press. <https://www.ipcc.ch/report/ar6/wg1/>
- Adeleke, O., et al. (2022). *Challenges in flood early warning systems in Sub-Saharan Africa*. [Source non précisée].
- UNDRR. (s.d.). *Global Assessment Report on Disaster Risk Reduction*. <https://www.undrr.org/publication/global-assessment-report-disaster-risk-reduction>
- Croix-Rouge camerounaise. (2022). *Rapport sur les inondations dans l'Extrême-Nord*. [Source non précisée].

REFERENCES WEBOGRAPHIQUES

- ❖ NASA. (s.d.). *POWER Data Access Viewer*. <https://power.larc.nasa.gov/>
- ❖ European Space Agency (ESA). (s.d.). *Copernicus Sentinel-2 Data*. <https://scihub.copernicus.eu/>
- ❖ Sinergise Ltd. (s.d.). *EO Browser*. <https://apps.sentinel-hub.com/eo-browser/>
- ❖ World Wildlife Fund (WWF). (s.d.). *HydroSHEDS: HydroRIVERS v1.0*. <https://www.hydrosheds.org/>
- ❖ GeoBoundaries. (s.d.). *GeoBoundaries: Open, Global Administrative Boundaries*. <https://www.geoboundaries.org/>
- ❖ Google. (s.d.). *Google Earth Engine*. <https://earthengine.google.com/>
- ❖ Centre for Research on the Epidemiology of Disasters (CRED). (s.d.). *EM-DAT: The International Disaster Database*. <https://www.emdat.be/>
- ❖ United Nations Office for the Coordination of Humanitarian Affairs (OCHA). (2024, September 12). *Cameroon: Floods in the Far North Region – Situation Report*. <https://www.unocha.org/>
- ❖ NASA/USGS. (s.d.). *Landsat Program*. <https://landsat.gsfc.nasa.gov/>
- ❖ NASA. (s.d.). *MODIS: Moderate Resolution Imaging Spectroradiometer*. <https://modis.gsfc.nasa.gov/>
- ❖ AGRHYMET Regional Centre. (s.d.). *AGRHYMET Data and Services*. <http://www.agrhymet.ne/>

TABLE DES MATIERES

DEDICACE.....	II
REMERCIEMENTS.....	III
RESUME	IV
ABSTRACT	V
INDEX DES TABLEAUX	VI
INDEX DES GRAPHIQUES.....	VII
LISTE DES SIGLES & ABBREVIATIONS	VIII
SOMMAIRE	IX
INTRODUCTION GENERALE.....	1
1. CONTEXTE GENERALE DE L'ETUDE	2
2. PROBLEMATIQUE DE L'ETUDE	2
2.1. <i>Problème général</i>	3
2.2. <i>Problèmes spécifiques</i>	3
3. HYPOTHESE DE L'ETUDE.....	3
3.1. <i>Hypothèse générale</i>	3
3.2. <i>Hypothèses spécifiques</i>	4
4. OBJECTIF DE L'ETUDE.....	4
4.1. <i>Objectif général</i>	4
4.2. <i>Objectifs spécifiques</i>	4
5. JUSTIFICATION DE L'ETUDE	4
5.1. <i>Au plan scientifique</i>	4
5.2. <i>Au plan pratique</i>	5
6. DELIMITATION DE L'ETUDE	6
6.1. <i>Au plan géographique</i>	6
6.2. <i>Au plan théorique ou thématique</i>	6
7. PLAN DU MÉMOIRE	7
CHAPITRE I : CADRE THEORIQUE & CONCEPTUEL	8
INTRODUCTION.....	9
1. CADRE CONCEPTUEL.....	9
1.1. <i>Définition & Présentation des concepts du sujet d'étude</i>	9
1.2. <i>Relation entre les concepts</i>	14
2. CADRE THEORIQUE & ETAT DE L'ART	16
2.1. <i>Présentation des théories & des modèles théoriques</i>	16
2.2. <i>Présentation de l'approche d'application dans le cas d'étude</i>	17
CONCLUSION	18
CHAPITRE II : METHODOLOGIE DE RECHERCHE.....	19

INTRODUCTION	20
1. NATURE ET VARIABLES DE RECHERCHE	20
1.1. <i>Nature de l'étude</i>	20
1.2. <i>Variables de l'étude</i>	21
2. ECHANTILLONNAGE & OUTILS DE L'ETUDE	23
2.1. <i>Echantillonnage & Collecte des données</i>	23
2.2. <i>Outils de l'étude</i>	26
CONCLUSION	27
CHAPITRE III: PRESENTATION D'ALTECHS ENGINEERING SARL & DONNEES COLLECTEES.....	28
INTRODUCTION	29
1. PRESENTATION D'ALTECHS ENGINEERING SARL.....	29
1.1. <i>Les services d'ALTECHS ING</i>	29
1.2. <i>Localisation</i>	31
1.3. <i>Structure/Organigramme d'ALTECHS ING</i>	32
2. DONNEES COLLECTEES	32
2.1. <i>Données météorologiques – NASA POWER</i>	32
2.2. <i>Données Satellites – Sentinel-2</i>	34
2.3. <i>Données Géographiques</i>	35
2.4. <i>Données historiques</i>	36
CONCLUSION	36
CHAPITRE IV : DIAGNOSTIC DE LA SITUATION ET PROPOSITION D'INTERVENTION.....	37
INTRODUCTION	38
1. PRESENTATION ET ANALYSE DE LA SITUATION	38
1.1. <i>Analyse des hypothèses</i>	38
1.2. <i>Limites et difficultés</i>	39
1.3. <i>Proposition d'un modèle et prospective</i>	40
2. INTERVENTION PROPOSEE ET JUSTIFICATION	41
2.1. <i>Objectifs de l'intervention – Projet envisagé</i>	41
2.1.1. <i>Objectif général</i>	41
2.1.2. <i>Objectifs spécifiques</i>	42
2.2. <i>Composantes de l'intervention envisagée</i>	42
2.2.1. <i>Composantes humaines</i>	42
2.2.2. <i>Composantes techniques</i>	43
2.2.3. <i>Composantes logicielles</i>	43
2.3. <i>Périmètre d'intervention, contenu de la solution et stratégies d'actions</i>	44
2.3.1. <i>Périmètre d'intervention</i>	44
2.3.2. <i>Contenu de la solution & Stratégies d'actions</i>	45
2.4. <i>Etude de la faisabilité</i>	58
CONCLUSION	59
CONCLUSION GENERALE.....	60

REFERENCES BIBLIOGRAPHIQUES	LXI
REFERENCES WEBOGRAPHIQUES	LXII
TABLE DES MATIERES	LXIII